

智识通 - 企业智能知识库系统

产品概述

智识通是一款基于RAG（检索增强生成）技术的企业级智能知识库问答系统。该系统能够将企业文档转化为可智能检索的知识库，通过大语言模型为用户提供精准、高效的问答服务。

核心功能

1. 智能文档管理

- 文档上传**: 支持 Word (.docx) 文档上传 (PDF 支持开发中)
- 自动分块处理**: 采用智能文本分割技术，将长文档切分为适合检索的语义片段
- 向量化存储**: 使用先进的Embedding技术将文档内容转化为向量，存储于ChromaDB向量数据库

2. 智能问答系统


- 语义检索**: 基于向量相似度检索，精准定位相关问题答案
- 上下文增强**: 自动整合检索到的相关文档片段，构建丰富的上下文提示
- 大模型生成**: 调用通义千问等大语言模型，生成准确、自然的回答
- 检索溯源 (基础版)**: 展示检索到的原始文档片段 (相似度分数、来源文档标识等详细追溯信息开发中)


3. Web交互界面

- 简洁美观的UI**: 现代化的界面设计，提供流畅的用户体验
- 单轮问答**: 支持基于知识库的智能问答 (多轮对话开发中)
- 文档管理**: 便捷的上传和管理企业文档

技术架构

系统架构图





核心技术栈

层级	技术组件	说明
Web框架	Flask 3.1.2	Python轻量级Web框架
向量数据库	ChromaDB 1.3.5	开源向量数据库, 支持持久化存储
大语言模型	通义千问 (qwen3.5-flash)	阿里云大语言模型API
Embedding模型	text-embedding-v4	阿里云文本向量化模型
文档处理	python-docx	Word文档解析
文本分割	LangChain	递归字符文本分割器

产品特性

1. 高精度语义检索

- 采用先进的Embedding技术, 将文本转化为高维向量
- 支持Top-N相似度检索, 精准定位相关内容
- 批量处理机制, 高效处理大规模文档

2. 多模型支持

- 默认集成阿里云通义千问系列模型

- 支持DeepSeek、腾讯混元等多种大模型
- 灵活配置，可根据需求切换不同模型

3. 中文优化

- 针对中文文档特别优化
- 支持中文文件名自动转拼音处理
- 使用jieba等中文分词工具

4. 数据持久化

- 向量数据本地持久化存储
- 支持多集合管理，便于分类存储不同文档
- SQLite后端，轻量且可靠

使用场景

1. 企业知识管理

- 人力资源政策问答
- 财务制度查询
- 产品手册智能检索

2. 客服智能助手

- 常见问题自动回答
- 产品咨询智能回复
- 服务流程引导

3. 教育培训

- 课程资料智能检索
- 学习问题答疑
- 知识点快速定位

快速开始

环境要求

- Python 3.11+
- 阿里云API Key（用于访问通义千问模型）

安装步骤

1. 安装依赖包

```
pip install -r requirements.txt
```

2. 配置API Key

```
# 设置环境变量
set DASHSCOPE_API_KEY=your_api_key_here
```

3. 启动服务

```
python RAG_Project/app.py
```

4. 访问系统 打开浏览器访问: <http://127.0.0.1:5000>

使用流程

1. 上传文档

- 访问 `/document_upload` 页面
- 选择 Word (.docx) 文档上传
- 系统自动解析并建立向量索引

2. 开始问答

- 访问首页 `/chat` 进入聊天界面
- 输入问题, 系统返回智能回答
- 查看引用的文档来源

项目结构

```
RAG_Project/
├─ app.py           # Flask web应用入口
├─ main.py          # RAG核心逻辑
├─ readme.txt       # 操作指南
├─ chroma/          # 向量数据库文件
│   └─ chroma.sqlite3 # SQLite数据库
├─ templates/       # HTML模板
│   └─ chat.html    # 聊天界面
│   └─ document_upload.html # 文档上传页面
└─ uploads/         # 上传文档存储目录

function_tools.py   # 工具函数库
models.py           # 模型配置与客户端
requirements.txt     # 依赖包列表
```

API接口说明

1. 文档上传

POST /document_upload/
Content-Type: multipart/form-data

参数:

- file: 文档文件 (.docx)

返回: 重定向到上传页面

2. 智能问答

POST /chat/ Content-Type: application/json

请求体: { "message": "用户问题" }

返回: { "response": "AI回答", "search_results": "检索到的相关文档内容" }

```
---

## 配置说明

### 模型配置 (models.py)

| 配置项 | 默认值 | 说明 |
|-----|-----|-----|
| ALI_TONGYI_TURBO_MODEL | qwen3.5-flash | 对话模型 |
| ALI_TONGYI_EMBEDDING_V4 | text-embedding-v4 | 向量化模型 |
| ALI_TONGYI_URL | dashscope.aliyuncs.com | API地址 |

### 系统参数

| 参数 | 默认值 | 说明 |
|-----|-----|-----|
| chunk_size | 300 | 文档分块大小 |
| chunk_overlap | 30 | 分块重叠大小 |
| n_results | 5/10 | 检索返回结果数 |
| temperature | 0 | 模型生成随机性 |

---

## 安全与隐私

- 所有文档数据本地存储，不上传到第三方
- API Key通过环境变量管理，不硬编码在代码中
- 支持文档级别的访问控制（通过集合名称隔离）

---

## 后续规划
```

近期优化

- ☒ 支持 PDF 文档上传和解析
- ☒ 支持多轮对话，保留会话上下文
- ☒ 增强检索可追溯性（相似度分数、来源文档标识、检索排名等）
- ☐ 支持更多文档格式（Excel、PPT、TXT等）
- ☐ 增加文档预览功能
- ☐ 优化检索算法，提升准确率

中长期规划

- ☐ 多用户权限管理
- ☐ 对话历史保存与回顾
- ☐ 知识库版本管理
- ☐ 多模态支持（图片、音频）

技术支持

如有问题或建议，请联系开发团队。

****版本****： v1.0

****最后更新****： 2026-03-06