

第三课：Function Calling 深度解析——从“自然语言”到“结构化执行”的范式转换

01

课程主题

项目	内容
课程主题	Function Calling深度解析（上）
课时安排	第1周第2次课（2小时）
学员基础	已掌握Agent基本概念，完成 LangChain Agent 实战，了解工具调用
教学目标	1. 理解 Function Calling 诞生的技术必然性 2. 掌握Function Calling的底层机制与范式转换 3. 完整理解从Prompt到API响应的全链路 4. Function Calling 调用数据库实例

02

环境准备

- Python 3.11+ 环境
- 大模型API密钥（建议OpenAI，因为 Function Calling 最成熟）
- 上节课的 LangChain Agent 代码
- 安装：`pip install langchain langchain-openai dotenv openai`

03

课程详情

第一部分：开场与上节回顾

1.1 【前言】

同学们好，欢迎回到 AI Agent 全栈开发课程的第三课。

上节课，我们完成了一次从理论到实践的重要跨越。我们亲手搭建了第一个 Agent。从三层架构的工程思维，到 LangChain 的代码实现，再到 OpenClaw 的自定义 SKILL 快速体验，大家已经能够写出一个带工具和记忆的 Agent 了。

但在这个过程中，有一个关键环节我们只是用到了，却没有深入探究：那就是 Agent 到底是怎么知道该调用哪个工具的？模型又是如何输出结构化指令的？

比如说，当你写了一个 `get_current_time` 函数，然后把它丢给 `create_agent`，Agent 就能在用户问‘现在几点’时自动调用它。这背后发生了什么？模型是怎么从一堆工具里选出正确的那一个？它又是怎么知道要把‘北京’这个参数填进去的？

这就是我们今天要深入探讨的主题——Function Calling。

1.2 【上节课核心回顾】

还是老习惯，在进入新内容之前，我们先快速回顾一下上节课的几个关键点，确保大家的基础是牢固的：

第一，三层架构：能力层（工具、模型、记忆）、业务层（决策、规划、整合）、表现层（CLI、API、聊天平台）。这个架构让我们写的 Agent 可维护、可扩展，而不是一坨‘意大利面’。

第二，LangChain 核心API：我们用 `create_agent` 创建了Agent，用 `@tool` 装饰器把普通函数变成工具。工具的描述文档——也就是函数的文档字符串——是模型决定何时调用的有效依据。

第三，记忆机制：我们通过 LangGraph 的 `StateGraph` + `Checkpointner` 实现了会话级记忆，让 Agent 不再是‘金鱼’——不仅能记住你是谁，还能记住曾经和你之前的对话内容。

第四，OpenClaw 对比：我们用 OpenClaw 的技能（Skill）机制快速复现了同样的功能，感受到了‘配置优先’、‘开箱即用’的便捷性。

可以说，上节课我们已经掌握了 Agent 开发的‘骨架’。但今天，我们要给这个骨架注入‘灵魂’——理解 Agent 到底是怎么思考和决策的。

1.3 【引出本节课主题】

那么，Agent 的思考决策，到底依赖什么？

答案就是 **Function Calling**。

如果你翻开 2023 年之前的 AI 技术文章，你会发现那时候想让模型‘调用工具’是一件非常痛苦的事——要靠提示词工程，写一大堆‘如果用户问天气，请输出{“tool”：“weather”，“city”：“...”}’，然后我们根据模型的输出写正则表达式去解析，再将解析后结果作为参数，最后再将这些参数传递给我们自定义函数执行，从而模拟模型调用工具。如果模型输出稍微错一点，整个程序就崩溃了。

2023 年 6 月，OpenAI 推出了 Function Calling，从此改变了游戏规则。模型开始原生支持输出结构化的函数调用指令，开发者只需要定义好函数签名和描述，剩下的交给框架。

可以说，Function Calling 是 Agent 能够‘动手’的技术基石。没有它，Agent 永远只能停留在‘对话’阶段——给你一堆建议，但无法真正执行。有了它，Agent 才能从‘军师’变成‘指挥官’。

下面，我们将从上到下、从外到内，彻底解剖 Function Calling 的每一个细节。大家会看到：

- 为什么 Function Calling 是必然出现的？（技术演进逻辑）
- 它到底是怎么工作的？（自然语言到结构化执行的范式转换）
- 从用户输入到 API 响应，完整链路是什么样的？（时序图 + 原生代码模拟）
- OpenClaw 在工具调用上做了什么更高层次的封装？（技能体系对比）

在这个过程中，我们会穿插大量代码和案例，让大家不仅知道‘怎么用’，更知道‘为什么要这样用’。

1.4 【课程结构预览】

下面，我们预告下今天的课程内容，主要分为三个主要部分：

第一部分：我们谈下为什么需要 Function Calling？

我们会回顾 Function Calling 诞生前的痛点，梳理技术演进路线，并对比传统提示词工程与 Function Calling 的优劣。这部分帮你建立‘技术必然性’的认知。

第二部分：机制解析——自然语言到结构化执行的范式转换

这是我们今天的核心。我们会深入 Function Calling 的底层原理：函数定义怎么写、模型如何决策、多函数场景如何处理。同时，我会带大家写一个高质量的‘天气查询’工具描述，让你感受描述细节对调用准确性的影响。

第三部分：全链路解析——从 Prompt 到 API 响应的完整工作流程

我们会画一张时序图，把一次 Function Calling 的完整交互过程拆解成多个步骤。然后，我会用原生 OpenAI SDK 手写一遍这个流程，让你看到框架到底帮我们封装了什么。

另外，在每个环节，我们都会穿插 OpenClaw 的工具调用机制分析，帮你建立跨框架的对比思维。

1.5 【过渡：进入第一部分】

好，这就是学习地图。我们先从第一个问题开始：为什么 Function Calling 是必然出现的？回到2023年之前，看看当时的开发者是怎么让模型‘调用工具’的——那种痛苦，会让你立刻理解 Function Calling 的革命性。

第二部分：Function Calling 诞生的技术必然性

2.1 从“文字游戏”到“指令执行”的痛点

2.1.1 【引入：回到“黑暗时代”】

在 Function Calling 出现之前，也就是 2023 年之前，开发者想让模型‘调用’某个函数，只能通过一种极其原始的方式——提示词工程。

想象一下，你要让模型帮你查天气。你在 Prompt 里写一堆指令，告诉模型：‘如果用户想查天气，请输出：`{"tool": "weather", "city": "beijing"}`’；‘如果用户想订机票，请输出 `{"tool": "flight", "from": "changsha", "to": "beijing"}`’；‘如果用户想计算数学，请输出 `{"tool": "calc", "expression": "2+6"}`’，如屏幕所示。

结果，当用户问这3个问题，模型就会按照要求返回这样格式的回复时，我们接下来程序会这么写：

代码块

```
1  if tool == "weather"
2      call_weather_api("beijing")
3  if tool == "flight"
4      call_flight_api("changsha", "beijing")
5  ...
```

看起来很直接，对吧？但实际操作起来，简直是噩梦。下面我们就来细数一下这么做的危害。

2.1.2 【痛点一：不可靠】

危害一：不可靠。

当你信心满满地把精心设计的 Prompt 发给模型，期待它返回完美的 JSON。但结果往往是这样的：

- 模型可能输出：`{"tool": "weather", "city": "北京"}` ——少了一个右括号，JSON解析直接报错。
- 或者它输出：`好的，我帮你查一下北京天气。{"tool": "weather", "city": "北京"}` ——前面多了一段解释文字，你需要用正则表达式从一堆文本里把 JSON 抠出来。
- 更夸张的：它可能直接输出 `北京今天晴`，根本不返回 JSON 字符串。

为什么会这样？因为模型本质上是一个语言模型，它被训练来生成自然语言，而不是结构化数据。让它输出 JSON，就像让一个诗人写代码——偶尔能写出漂亮的结果，但有一定概率会跑偏。

为了应对这些问题，开发者不得不写大量的正则表达式去解析输出，而且每次模型升级，Prompt 还得重新调优。这就像你让一个实习生帮你做事，但每次都要写一份极其详细的说明书，而且他还会时不时把说明书理解错。你大部分时间不是在写业务逻辑，而是在给模型擦屁股。

2.1.3 【痛点二：不安全】

危害二：不安全。

模型输出的 JSON 可能包含恶意内容。想象一下，你在 Prompt 里定义了一堆工具，其中可能有一个 `exec_command` 用来执行系统命令。

结果模型如果被诱导，可能会输出：

代码块

```
1 {"tool": "exec_command", "command": "rm -rf /"}
```

如果你直接执行这个JSON，后果将不堪设想——整个系统都可能被删除。

所以，你必须在解析代码逻辑加一层严格的安全校验：

- 检查函数名是否在白名单里
- 检查参数类型是否正确
- 检查参数值是否在允许范围内

这一整套安全逻辑写下来，检查代码比业务逻辑代码还多。而且一旦有遗漏，就可能会留下安全隐患。

更可怕的是，你根本不知道模型在什么情况下会输出什么样的内容。即使你今天测试通过了，明天模型一更新，可能又会输出一些你意想不到的东西。安全，就成了悬在头顶的达摩克利斯之剑。

2.1.4 【痛点三：不通用】

危害三：不通用。

每个新工具都要重新设计 Prompt，而且当时不同的模型对 JSON 格式的偏好还不一样。

- 你用 GPT-3.5，它可能习惯输出 `{"tool": "weather", "city": "北京"}`；
- 换到 Claude，它可能更喜欢 `<tool>weather</tool><city>北京</city>` 这种 XML 格式；
- 换成国产模型，它可能又有一套自己的风格。

这意味着什么？你写了一套 Prompt，今天跑得好好的，明天想换一个其他的模型，就要把整个 Prompt 重写一遍。如果你的应用依赖多个模型，维护成本直接爆炸。

而且，每增加一个新工具，你都要在 Prompt 里增加关于自定义工具的一大段描述，这些描述还可能相互干扰。比如，你加了天气工具，可能影响了计算器工具的调用准确性。

总之，传统提示词工程的方式，让工具调用变成了一种‘手工艺品’——每次都要精雕细琢，但成品依然脆弱、不安全、不通用。

2.1.5 【结语：呼唤标准化】

所以，行业急需一种标准化的方式，让模型能够直接输出结构化的函数调用指令，并且由框架安全地执行。

这就像 USB 接口统一了外设连接——你不需要为每一个鼠标、键盘写不同的驱动程序，插上去就能用。Function Calling 要做的，就是统一模型与所调工具的交互方式。

开发者只需要定义好函数签名和描述，模型就会返回可靠的、结构化的调用指令。框架负责安全执行。不需要正则表达式，不需要安全校验，也不需要为每个模型写不同的 Prompt。

这就是 Function Calling 诞生的背景。它不是某个公司的营销噱头，而是现实技术演进的必然产物。没有它，Agent 就永远只能停留在‘对话’阶段，无法真正执行任务，调用外部工具。

2.2 技术演进：从 Function Calling 到 Agent 框架

2.2.1 【开场：从“点”到“面”的演进】

刚才，我们回顾了 Function Calling 诞生前的‘黑暗时代’——传统提示词工程的三大痛点：不可靠、不安全、不通用。下面我们再介绍下，Function Calling 是如何一步步从一颗种子，长成今天 Agent 生态的参天大树的。

接下来，我们沿一条清晰的时间线，看看 Function Calling 的普及，如何催生了整个 Agent 框架的繁荣。

2.2.2 【时间轴：四个关键节点】

我们来看这条时间轴。它清晰地展示了 Function Calling 从诞生到成为 Agent 基础设施的完整演进过程。

2023年：OpenAI 发布 Function Calling

2023年6月，OpenAI 在 GPT-4 和 GPT-3.5 中正式引入 Function Calling。这是模型的一次升级，也算是第一个工业级的标准化实现。开发者可以在调用 openai API 中传递函数定义，模型理解函数定义后返回标准的、结构化的 `function_call` 指令。

这次发布的意义，不亚于当年 HTTP 协议的诞生。它第一次让模型能够以可靠、安全的方式与外部世界交互。开发者不再需要写复杂的 Prompt 和正则表达式，只需要定义好函数签名，剩下的交给框架。

2024年：各大模型厂商跟进

2024年，Function Calling 迅速成为行业标准。

- Anthropic 的 Claude 推出 Tool Use——虽然名字不同，但核心思想一致。
- Google 的 Gemini 也推出 Function Calling 能力。
- 国产模型也不甘落后：智谱AI、阿里通义、月之暗面纷纷支持类似功能。

到 2024 年底，几乎每一款主流大模型都具备了 Function Calling 能力。这意味着，开发者可以在不同模型之间自由切换，而不用重写工具调用逻辑。模型的竞争，从‘谁能生成更好的文本’，扩展到了‘谁能更准确地调用工具’。

2024-2025年：框架层封装

时间来到 2024 到 2025 年，LangChain、AutoGen 等框架开始将 Function Calling 作为核心能力封装。

开发者不再需要手写两次 API 调用、解析 `function_call`、注入函数结果——框架默默替你承担了所有。你只需要用 `@tool` 装饰器定义函数，框架会自动生成函数定义、处理调用流程、管理对话状态。

这个阶段，Function Calling 从‘开发者手搓’变成了‘框架内置’。开发效率提升了不少数量级，Agent 开发的门槛也开始大幅降低。

2025-2026年：Agent框架爆发

2025 到 2026 年，以 OpenClaw 为代表的新一代 Agent 框架，将工具调用提升到‘技能（Skill）’层面。

它们不仅封装了 Function Calling 的底层，还提供了：

- **技能市场：**全球开发者共享技能，就像 App Store 一样。
- **多模型路由：**根据不同任务自动选择最合适的模型。
- **记忆管理：**内置短期和长期记忆，开箱即用。
- **多平台支持：**可以部署在 Slack、飞书、微信等聊天平台。

在这个阶段，Function Calling 不再是开发者需要关心的技术细节，而是变成了‘技能’这一更高层抽象的基础设施。

2.2.3【讲师强调：从“会说话”到“会发指令”】

从这条时间线的演进，告诉了我们一个清晰的趋势：Function Calling 的普及，让模型从‘会说话’变成了‘会发指令’。

- 在 Function Calling 出现之前，模型只能输出文本——它最多是个‘话痨’，能说会道，但做不了任何实事。
- Function Calling 让模型能够输出结构化的指令——它变成了一个‘指挥官’，能够精准地调度外部工具。
- 而 Agent 框架，则在这个基础上，赋予了模型‘规划’、‘记忆’、‘反思’的能力——让它从一个只会发指令的‘指挥官’，变成了一个能够自主决策的‘CEO’。

可以说，Function Calling 是 Agent 框架能够实现自动规划、自主决策的基础。没有它，后面所有的多步推理、反思改进、多智能体协作都无从谈起。就像没有地基的大厦，盖得越高，塌得越快。

2.3 Function Calling vs 传统提示词工程

2.3.1【开场：两种范式的本质差异】

好，刚才我们回顾了 Function Calling 从诞生到成为 Agent 基础设施的演进历程。下面为了直观性，我们再做一个更直接的对比——把传统提示词工程和 Function Calling 放在一起，看看它们在可靠性、

安全性、开发效率等维度上，到底差在哪里。

为了让大家看得更清楚，我准备了一张对比表。

2.3.2 【对比表格：八维较量】

维度	传统提示词工程	Function Calling
可靠性	依赖Prompt调优，输出格式不稳定，常有错漏，需正则解析	原生支持，结构化输出保证，无需解析
安全性	需手动白名单校验，参数类型检查，易遗漏	框架层面隔离，只执行预定义函数
开发效率	每个工具要写长篇 Prompt，不同模型需适配	只需定义函数签名和描述，框架自动生成
模型适配	不同模型 Prompt 格式差异大，迁移成本高	统一接口，框架自动转换格式
可扩展性	添加新工具需修改Prompt，可能影响已有功能	添加新函数定义即可，互不干扰
调试难度	只能通过输出文本判断，难以定位问题	可追踪function_call，通过LangSmith
维护成本	Prompt 版本管理困难，每次模型升级需重调	函数定义与模型解耦，升级影响小
表达能力	只能描述简单函数调用，复杂嵌套需层层Prompt	支持嵌套函数、参数结构，原生支持

下面我们逐行解读：

- 1. 可靠性：**传统方式下，模型输出 JSON 是‘建议’，而且会经常走样；Function Calling 下，输出是‘结构’，格式固定，可靠得多。
- 2. 安全性：**传统方式下，你要自己写一堆校验代码，容易漏；Function Calling 下，只执行你定义好的函数，参数也自动校验，安全有保障。
- 3. 开发效率：**传统方式每个工具都要写一大段 Prompt，还可能要调试半天；Function Calling 只需要写一个函数签名和描述，框架帮你生成函数定义。
- 4. 模型适配：**传统方式下，换模型等于重写 Prompt；Function Calling 下，框架自动适配不同模型格式，开发者无感知。
- 5. 可扩展性：**传统方式添加一个新工具，要在 Prompt 里插一段描述，可能打乱原有逻辑；Function Calling 下，加一个函数定义就行，互不影响。
- 6. 调试难度：**传统方式只能看输出文本，不知道模型内部怎么想的；Function Calling 下，可以通过 LangSmith 等工具看到每一步的 `function_call`，精准定位。
- 7. 维护成本：**传统方式下 Prompt 版本管理混乱，模型升级可能打破格式；Function Calling 下，函数定义相对稳定，升级影响小。
- 8. 表达能力：**传统方式只能处理简单的函数调用，参数嵌套、多步调用很难描述；Function Calling 原生支持复杂的参数结构，甚至支持嵌套函数。

2.3.3 【深度剖析：“假装”与“真正”的鸿沟】

上面那张表从八个维度展示了提示词和 Function Calling 这两种方式的差距。但最根本的区别，其实可以概括为一句话：

传统方式是你让模型‘**假装**’调用工具，而 Function Calling 是模型‘**真正**’学会调用工具。

怎么理解这句话？

传统方式：你在 Prompt 里写‘如果用户问天气，请输出 JSON...’。模型看到这个指令，它并不知道什么叫‘调用函数’，它只是在模仿你给的例子，生成一段看起来像 JSON 的文本。它本质上还是在做文本生成，只不过生成的内容恰好符合你的预期。一旦例子不够清晰，或者用户问法变了，它就‘演’不下去了。这就像让一个演员在舞台上假装打电话——他能做出打电话的动作，但他并不是真的在和谁通话。

Function Calling：模型在训练阶段就被教会了‘函数调用’这个原生能力。它知道有一个叫 `get_weather` 的函数，知道这个函数需要一个 `city` 参数，知道在什么场景下应该调用它。当用户问‘北京天气’时，它不是模仿输出 JSON，而是真的在‘思考’：‘这是一个天气查询，我应该调用 `get_weather` 函数，参数是北京’。然后，它输出一个结构化的调用指令——这不是模仿，而是它的 **原生** 输出形式。

这种差异带来了质变：

- 从‘**文本生成**’到‘**指令生成**’：模型输出的内容从‘给人看的文字’变成了‘给程序执行的指令’。
- 从‘模拟’到‘原生’：不需要靠 Prompt 来‘教’模型怎么输出格式，模型本身被训练天然就懂。
- 从‘脆弱’到‘稳定’：模型对函数调用的理解是深层的，不是表层模仿，所以更可靠。

这正是我们称 Function Calling 是模型‘范式转换’的原因——它让模型从‘文本生成器’变成了‘指令生成器’。前者只能提供信息，后者能够发起行动。

其实从这个时候起，就给未来科技种下了一颗种子，也就是模型输出其实不应该仅仅给人看，还应该让机器看得懂，随着时代的进化，也许后面的时代更多是模型跟模型自己对话的时代，慢慢人的认知就赶不上时代的发展了。

2.3.4 【过渡：进入全链路解析】

理解了传统方式和 Function Calling 的本质差异，我们就能更深入地探究 Function Calling 的内部机制。它到底是怎么实现‘指令生成’的？模型是怎么从一堆函数定义中选出正确的那一个？参数又是怎么提取的？

下面，我们将进入全链路解析——从用户输入到 API 响应，完整走一遍 Function Calling 的工作流程。我们会画时序图、写原生代码，彻底揭开黑盒。

第三部分：机制解析——自然语言到结构化执行的范式转换

3.1 Function Calling 的核心原理

3.1.1 【开场：进入“黑盒”内部】

下面我们就要走进 Function Calling 的核心了。前面我们讲了它诞生的必然性，对比与传统方式的优劣，但还没真正看到它内部是如何运转的。

接下来，我们要把这个黑盒打开。以一个简单的天气查询为例，一步一步进行拆解，比如：当你问‘北京天气怎么样’，模型是怎么知道要调用 `get_weather` 这个函数的？它又是怎么把‘北京’这个参数提取出来的？

整个过程可以分为五步。我把它叫作‘Function Calling 的五部曲’——每一部都清晰、严谨、可编程。

3.1.2 【第一部：开发者定义工具函数】

第一步：开发者首先需要定义工具函数。

以 OpenAI 的 API 为例，函数定义是一个 JSON 对象。我们来看一个天气函数的定义：

代码块

```
1  {
2      "name": "get_weather",
3      "description": "获取指定城市的天气信息",
4      "parameters": {
5          "type": "object",
6          "properties": {
7              "city": {
8                  "type": "string",
9                  "description": "城市名称，如'北京'"
10             }
11         },
12         "required": ["city"]
13     }
```

```
13     }
14 }
```

注意看，这个定义里有三个关键信息：

- **name**：函数的名字，模型输出时会用到。
- **description**：对函数功能的描述，模型靠它判断什么时候该调用这个函数。这里写‘获取指定城市的天气信息’，模型就知道这个函数是用来查天气的。
- **parameters**：参数结构，遵循 JSON Schema 格式。这里说明参数 `city` 是字符串类型，并且是必需的。

这个定义就是开发者和模型的契约。开发者告诉模型：‘我有一个工具，叫 `get_weather`，它需要城市名，你可以在合适的时机调用它。

3.1.3 【第二步：把函数定义传给模型】

第二步：发送请求时，把函数定义传给模型。

在 OpenAI API 请求中，我们需要在 `functions` 参数里传入上面工具函数的定义。同时，还可以通过 `function_call` 参数控制模型的行为——是自动决定（`auto`）、强制不调用（`none`），还是强制调用某个函数。

典型的请求体长这样：

代码块

```
1  {
2      "model": "gpt-4",
3      "messages": [{
4          "role": "user",
5          "content": "北京天气怎么样？"
6      }],
7      "functions": [上面的函数定义],
8      "function_call": "auto"
9  }
```

这里 `function_call: "auto"` 告诉模型：你自己判断是否需要调用函数。你也可以指定 `"function_call": {"name": "get_weather"}`，强制模型调用这个函数，但一般不这么做，因为我们希望模型自主决策。

3.1.4 【第三步：模型决策并返回调用指令】

第三步：模型处理用户输入，决定是否调用函数。

模型收到请求后，会分析用户消息和函数定义。它发现用户问‘北京天气怎么样’，而有一个函数 `get_weather` 的描述是‘获取指定城市的天气信息’，于是判断：应该调用这个函数。

然后，模型会返回一个 `function_call` 对象，而不是直接返回文本。就像这样：

代码块

```
1  {
2      "function_call": {
3          "name": "get_weather",
4          "arguments": "{\"city\": \"北京\"}"
5      }
6  }
```

注意，`arguments` 是一个JSON字符串，里面包含了调用函数所需的参数。模型根据用户输入提取出‘北京’作为 `city` 的值。

这里有一个关键点：模型输出的不再是自然语言，而是结构化的指令。这就是‘指令生成器’的体现。你可以直接用程序解析这个JSON，拿到函数名和参数，然后去调用真实的函数。

3.1.5 【第四步：开发者执行函数，返回结果】

第四步：开发者执行函数，并把结果返回给模型。

这一步是开发者需要做的。我们拿到模型返回的 `function_call` 这样的指令后，我们解析出函数名和参数，然后调用我们自己开发的真实的 `get_weather` 函数。

真实函数定义为：

代码块

```
1  def get_weather(city):
2      """模拟天气查询函数"""
3      weather_data = {
4          "北京": {"weather": "晴", "temp": "5-15°C"},
5          "上海": {"weather": "阴", "temp": "8-18°C"},
6          "广州": {"weather": "多云", "temp": "15-25°C"},
7          "深圳": {"weather": "小雨", "temp": "18-22°C"}
8      }
9      return weather_data.get(city, {"weather": "未知", "temp": "未知"})
```

假设真实函数返回：

代码块

```
1  {
2      "weather": "晴",
3      "temp": "5-15°C"
4  }
```

然后，我们需要第二次调用模型API。这次，我们不仅要传原来的消息历史，还要把模型刚才返回的 `function_call`，以及函数执行的结果，都作为新消息加进去。

第二次请求的 `messages` 长这样：

代码块

```
1  [
2      {
3          "role": "user",
4          "content": "北京天气怎么样？"
5      },
6      {
7          "role": "assistant",
8          "content": null,
9          "function_call": {
10             "name": "get_weather",
11             "arguments": "{\"city\": \"北京\"}"
12         }
13     },
14     {
15         "role": "function",
16         "name": "get_weather",
17         "content": "{\"weather\": \"晴\", \"temp\": \"5-15°C\"}"
18     }
19 ]
```

注意这个特殊的 `role: "function"` ——它专门用来承载函数执行的结果。模型看到这个消息后，就能知道工具调用的结果，然后据此生成最终回复。

这一轮请求，我们不再传 `functions` 参数，因为模型已经完成工具调用决策了，现在只需要把结果翻译成自然语言。

3.1.6 【第五步：模型生成最终回答】

最后一步：模型根据函数结果生成自然语言回答。

第二次调用模型API后，模型看到函数结果，会输出最终的自然语言回复。比如：

代码块

```
1  {
2      "response": [{
3          "message": {
4              "role": "assistant",
5              "content": "北京今天晴，气温5-15°C。"
6          }
7      }]
8  }
```

这就是我们最终展示给用户的答案。

整个过程，模型完成了两次‘思考’：

- 第一次：理解意图，决定调用哪个工具，提取参数。
- 第二次：把工具返回的原始数据，组织成人类友好的回答。

这种‘两次调用’的模式，就是 Function Calling 的标准流程。

3.1.7 【范式转换的体现】

现在，我们回过头来看这个五步流程，就能更深刻地理解什么是‘范式转换’。

在传统提示词工程中，模型只输出一文本，开发者要从中解析出信息。模型既不知道自己在调用工具，也没有工具调用这个概念。

在 Function Calling 中，模型输出的不再是文本，而是结构化的指令。它明确知道自己是在调用函数，并且能够精确地提取参数。开发者只需要安全地执行函数，再把结果喂回去，模型就能整合成自然语言。

这个过程中，模型不再只是‘猜’用户意图，而是能够精确地输出函数调用。而且函数调用是结构化的，可以被程序安全地解析和执行。

这就是 **自然语言** 到 **结构化执行** 的范式转换。

3.1.8 【模拟提问】

也许会有学员会问：‘为什么需要两次调用？一次不行吗？’

——好问题。

1. 第一次调用是为了让模型做决策：要不要调用工具、调用哪个、参数是什么。
2. 第二次调用是为了让模型把工具返回的原始数据翻译成自然语言。

所以这里必须要有两次调用。

也许有朋友会问：‘如果模型决定不调用工具呢？’

——当模型根据提供的信息决定没有调用工具的必要，那么它返回结果中就没有 `function_call` 字段，而是直接返回自然语言结果。这种情况我们就不需要第二次调用了，直接把模型输出作为最终答案返回给用户。所以我们在处理实际模型返回结果中判断是否有 `function_call` 字段，然后根据是否有该字段，然后决定走不同分支。

3.2 函数描述的重要性：如何让模型准确调用

3.2.1 【描述是“说明书”】

好了，Function Calling 核心原理我们讲完了。从定义函数、传递定义、模型决策、执行函数、返回结果，五步环环相扣。但这里有一个细节不知道大家是否注意到了，那就是前面在第一步定义函数时，我们写了一个 `description` 字段——‘获取指定城市的天气信息’。这个描述看起来不起眼，但它其实是 Function Calling 的灵魂。

为什么？因为模型就是靠这段描述来判断什么时候该调用哪个函数。如果描述写得不清晰，模型可能该调的时候不调，不该调的时候乱调。下面我们就来深入探讨一下：如何写出能让模型准确调用的函数描述。

3.2.2 【三个要素：功能说明、触发条件、参数含义】

一个好的函数描述，应该包含三个要素：

第一：功能说明。这个函数是做什么的？用一句话概括核心功能。比如‘获取指定城市的实时天气信息’。

第二：触发条件。什么时候应该调用？最好给出具体的使用场景或例子。比如‘当用户询问某个城市的天气、温度、降水情况时，可以调用此工具’。这能帮助模型把自然语言中的关键词和工具关联起来。

第三：参数含义。每个参数代表什么？有没有格式要求或特殊限制？比如 `city` 参数是城市名称，并给出示例‘北京’、‘上海’。

这三个要素缺一不可。功能说明让模型知道工具能做什么；触发条件让模型知道什么时候用；参数含义让模型知道怎么填参数。

3.2.3 【对比案例：好描述 vs 差描述】

下面我们举个实际例子：通过对比两个描述，看看差异到底有多大。

第一个描述（差）：

‘获取天气’

这个描述太笼统了。模型可能会困惑：‘天气’指的是实时天气还是天气预报？温度算不算？要不要包含降水？而且没有触发条件，模型不知道什么时候该调用。如果用户问‘明天出门要带伞吗’，模型可能不调用，因为没出现‘天气’这个词。

第二个描述（好）：

‘获取指定城市的实时天气信息。当用户询问某个城市的天气、温度、降水情况时，可以调用此工具。参数 city 是城市名称，如‘北京’、‘上海’。

这个描述非常清晰：

- 首先：功能明确说明。获取指定城市的实时天气信息。
- 其次：触发条件具体。天气、温度、降水情况。模型看到‘带伞’就知道跟降水相关，看到‘冷不冷’就知道跟温度相关，都会调用。
- 最后：参数有示例。city 是城市名称，而且给了两个例子，模型很容易提取。

实际效果差异：用第一个描述，用户问‘北京今天冷不冷’，模型可能不调用，因为它觉得‘冷不冷’不是‘天气’。用第二个描述，模型会判断‘冷不冷’属于‘温度情况’，于是调用工具。这就是描述细节决定调用准确性的典型例子。

工具描述并不过时，并非只适用于 Function calling，即使是 LangChain 工具调用，甚至是龙虾，好的工具描述都是不可或缺的。下面我们顺便介绍下 LangChain 和 OpenClaw 工具调用方面的描述。

3.2.4 【LangChain中的写法：文档字符串】

在 LangChain 中，函数描述就是函数的文档字符串（docstring）。你写的每一行注释，都会被 LangChain 提取并转换成模型看到的函数定义。

示例如下：

代码块

```
1 @tool
```

```
2 def get_weather(city: str):
3     """获取指定城市的实时天气信息。当用户询问某个城市的天气、温度、降水情况时，可以调用此
    工具。参数：city：城市名称，如'北京'、'上海'。返回：包含天气状况和温度的信息。"""
```

这里的关键是：第一行简明扼要，后面用自然语言描述触发条件和参数。LangChain 会自动把这些文本转换成 API 需要的 `description` 和 `parameters.description`。

注意：不要只写一句话。写详细一点，模型理解得更准确。

3.2.5 【OpenClaw中的写法：SKILL.md】

在 OpenClaw 中，描述会写在 `SKILL.md` 文件里。它的风格更偏向自然语言，因为 OpenClaw 的设计哲学是让非技术人员也能定义技能。

标准写法示例：

代码块

```
1  ## get_weather
2  获取指定城市的实时天气信息。当用户询问某个城市的天气、温度、降水情况时，可以调用此工具。
3  输入参数：
4      - `city` (string): 城市名称，如“北京”、“上海”。
5  返回：
6      包含天气状况和温度的信息。
```

OpenClaw 在运行时，会把 `SKILL.md` 里的描述嵌入到系统提示中，模型看到的就是这段自然语言。所以，描述写得好不好，直接决定模型会不会调用这个技能。

对比 LangChain：LangChain 的描述是代码的一部分，而 OpenClaw 的描述是独立的 Markdown 文件。前者更适合开发者在代码中维护，后者更适合团队协作——产品经理可以写描述，工程师实现代码。

3.2.6 【互动】

曾经有学员问：‘那描述写多长合适？有没有长度限制？’

——这其实是一个很好的问题。描述没有硬性的 token 限制，但一般建议控制在 50-200 个字符之间。太短了信息不够，太长了模型可能抓不住重点。关键是用最少的文字传递最关键的触发条件。

也曾经有学员会问：‘如果描述写错了，模型会怎么样？’

——如果描述和函数实际功能不符，模型会调用错误，导致执行失败。比如你描述写得是‘查询天气’，但实际函数是查空气质量，用户问天气时模型会调用这个查询空气质量的函数，返回的是空气质量数据，用户就会困惑。所以描述必须和实际功能严格一致。

3.2.8 【过渡：下一节内容】

上面我们深入了函数描述的重要性，并进行了 Function Calling、LangChain、OpenClaw 的函数描述字符串之间的对比。

3.3 多函数场景与自动路由

3.3.1 【开场：从“单工具”到“工具箱”】

接下来，我们进入一个更复杂的场景：多函数场景与自动路由。大家都知道，在实际应用中，Agent 很少只有一个工具。它更像一个工具箱，里面放着扳手、螺丝刀、电钻、锤子……用户的需求可能涉及多个工具，甚至需要按顺序使用。当 Agent 面对多个工具时，模型怎么从一堆函数里选出最合适的那一个？如果用户输入涉及多个意图，模型怎么处理？两个工具功能相似时，模型又该如何区分？

下面，我们就来一一解开这些问题。

3.3.2 【什么是自动路由？】

自动路由，简单说就是：模型根据用户输入，从多个可用的工具中自动选择最合适的一个（或一组）来执行。

你可以把它想象成一个智能路由器：用户发来一个请求，路由器的核心，这里也就是指模型来分析这个请求，然后决定把请求转发给哪个‘后端服务’，也就是工具。

在单工具场景下，路由很简单——只有一条路，模型只需要判断‘要不要调用’。

但在多工具场景下，路由变得复杂了。模型需要做三件事：

1. 选择：从多个工具中选出正确的那一个。
2. 排序：如果多个工具都需要调用，决定先后顺序。
3. 依赖管理：如果后一个工具依赖前一个工具的结果，要确保顺序正确。

3.3.3 【多工具场景的三大挑战】

从此可知，多工具场景给模型带来了三大挑战。这三大挑战，我们逐一来看：

挑战一：功能重叠

假设你有两个工具：

- `get_weather_simple(city)`：返回天气概况，如‘晴，5-15°C’
- `get_weather_detailed(city)`：返回详细天气，包括湿度、风力、紫外线指数、降水概率

当用户问‘北京天气怎么样’，模型该调用哪个？如果用户只是想知道大概，调用简单的就够了；但如果用户是户外运动爱好者，可能需要详细的。模型需要从对话历史、用户偏好中推理出应该用哪个。

挑战二：多意图混合

用户说：‘帮我查一下北京的天气，然后订一张去上海的机票，哦对了，再提醒我明天开会。’

这包含了三个意图：查天气、订机票、设置提醒。模型需要识别出这三个意图，并决定调用的顺序。先查天气再订机票？还是先订机票再查天气？天气可能影响出行决定，所以合理的顺序是：查天气 → 订机票 → 设置提醒。

挑战三：依赖关系

有些任务存在天然的依赖关系。比如：

- 用户说‘帮我订一张明天去北京的机票’，你需要先知道‘明天’是几号，可能涉及日期计算。
- 或者用户说‘帮我分析一下特斯拉的股价’，你需要先调用股票数据工具，拿到数据后才能调用分析工具。

模型需要理解这些依赖关系，并规划出正确的执行顺序。如果顺序错了，整个任务就会失败。

这些挑战对模型的推理能力要求很高。模型不仅要理解用户说了什么，还要理解工具之间的关系，以及如何规划步骤。这就是为什么2025年下半年开始，模型推理能力（如思维链、思维树）成为各大厂商的竞争焦点。

实际上这样的多函数场景用 Function Calling 处理起来是相当吃力的。

作为开发，你需要很多浇水、判断和手工活才能做到。

但碰到这样的复杂场景该如何解决呢？答案就是 Function Calling 以后的接替者 LangChain 和 OpenClaw。

3.3.4 【LangChain 处理方式】

我们先看 LangChain 是如何处理多工具场景的，简单说明那就是：

代码块

```
1 create_agent + 工具列表 + 自动编排
```

当你用 `create_agent` 创建Agent，并传入一个包含多个工具的列表时，LangChain 内部会自动处理多工具场景。它的工作流程是这样的：

1. 模型输出工具调用序列：模型会输出一个或多个 `function_call`，形成一个序列。比如，模型可能先输出 `get_weather`，再输出 `book_flight`，再输出 `create_reminder`。
2. Agent 执行器依次执行：LangChain 框架会循环处理这个序列。每遇到一个工具调用，就执行对应的函数，然后把结果追加到对话历史中。
3. 持续直到完成：执行完所有工具后，Agent 会把所有结果汇总，再调用一次模型生成最终回复。

代码层面：你不需要写任何额外的逻辑。只要把多个工具放进 `tools` 列表，剩下的交给 LangChain。

代码块

```
1 agent = create_agent(  
2     model=model,  
3     tools=[get_weather, book_flight, create_reminder], # 多个工具  
4     system_prompt="你是一个智能助手..."  
5 )
```

因此，如果当用户说‘查天气并订机票’时，Agent 会自动完成多步调用。

3.3.5 【OpenClaw 处理方式】

说完 LangChain，我们接着再来介绍 OpenClaw。

OpenClaw 的处理方式略有不同，它更强调技能的动态调用。

OpenClaw 的方式：技能系统 + 自然语言调度

在 OpenClaw 中，每个工具都是一个独立的技能（Skill）。模型在对话中可以动态决定调用多个技能，OpenClaw 框架负责解析和调度。

OpenClaw 工具调用的特点如下：

- 第一：自然语言驱动。模型输出的技能调用是自然语言格式，比如‘调用 `get_weather` 技能，参数 `city=北京`’，而不是结构化的 JSON。OpenClaw 会解析这个自然语言并执行。
- 第二：技能独立性。每个技能只关心自己的输入输出，不关心其他技能。技能之间的协作由模型在推理中完成。

- 第三：灵活性强。你可以随时添加新技能，不需要修改任何代码。模型会自动学习新技能的存在（通过 `SKILL.md`）。

举例说明：用户说‘查北京天气，然后订去上海的机票’。模型可能会输出：

‘先调用 `get_weather` 技能，参数 `city = 北京`。得到天气后，再调用 `book_flight` 技能，参数 `from = 北京, to = 上海`。’

OpenClaw 解析出这两个调用，依次执行，把结果返回给模型，模型再生成最终回答。

3.3.6 【示例演示：多步工具调用】

下面我们再总结下智能 Agent 到底是如何实现多步工具调用的。

这里，我们演示一个完整的多步调用示例来说明。

当用户输入：‘帮我查一下北京天气，然后订一张明天去上海的机票。’

模型内部推理（简化的思维链）：

用户有两个需求：查天气和订机票。订机票可能受天气影响，所以我应该先查天气，再订机票。如果有雨，可能需要提醒用户带伞。

第一步：调用 `get_weather`，参数 `city=北京`。

第二步：拿到天气结果后，调用 `book_flight`，参数 `from=北京, to=上海, date=明天`。

Agent 框架执行：

1. 执行 `get_weather("北京")`，返回‘北京明天晴，5-15°C’。
2. 将天气结果加入对话历史。
3. 执行 `book_flight("北京", "上海", "明天")`，返回‘已预订，航班号MU1234’。
4. 将订票结果加入对话历史。
5. 将完整对话再次发给模型，模型最终回答：‘北京明天晴，5-15°C，适合出行。我已为你预订明天北京飞上海的MU1234航班。’

整个过程，模型规划了顺序，框架负责执行，用户得到完整的服务。

3.3.7 【强调：推理能力是关键】

要知道，多函数场景对模型的推理能力要求很高。模型不仅要理解意图，还要规划顺序、处理依赖。这就是为什么2025年下半年开始，模型推理能力（如思维链Chain-of-Thought、思维树Tree-of-Thoughts）成为各大厂商的竞争焦点。

一个模型能调用多少工具、能处理多复杂的多步任务，直接决定了它离‘真正的智能体’有多远。

讲完了多函数工具调用后，我们再把思绪重新再拉到 Function Calling。

我们将进入 Function Calling 全链路解析，从用户输入到 API 响应，完整走一遍 Function Calling 的工作流程。

第四部分：全链路解析——从Prompt到API响应的完整工作流程

4.1 时序图：一次典型 Function Calling 的完整交互

4.1.1 【开场：把“黑盒”变成“透明箱”】

总结来说，Function Calling 整个工作流程共包含 9 个步骤。下面我会带着大家一步一步走完。了解完这9个步骤，你就彻底理解了Function Calling 的底层交互逻辑。

4.1.2 【步骤1-2：用户输入与构建请求】

步骤1：用户输入。

用户说了一句话：‘北京天气怎么样？’这是整个流程的起点。在命令行里，就是 `input()`；在 Web 界面里，就是用户敲回车的那一刻。

步骤2：编码构建第一次请求。

收到用户输入后，我们需要写程序来打包 API 请求。这里包含三样东西：

- 用户消息： `{"role": "user", "content": "北京天气怎么样?"}`
- 系统提示：比如 ‘你是一个友好的AI助手’（如果有的话）
- 函数定义：我们之前定义的 `get_weather` 函数的JSON描述

这个请求被打包好，发送给模型。

这两步操作只是告诉模型：‘这里有用户消息，这里有工具定义，模型你看看根据用户消息需不需要调用工具。’

4.1.4 【步骤3-4：模型决策与解析】

步骤3：模型返回 `function_call`。

模型收到调用请求后进行分析。它看到用户问‘北京天气’，又看到有一个工具函数定义是 `get_weather`，该工具函数描述是‘获取指定城市的天气信息’。经过分析，模型得出判断：应该调用这个函数。

于是，模型返回一个 `function_call` 对象，而非直接返回用户问题答案。此时，这个对象长以下这样：

代码块

```
1  {
2      "function_call": {
3          "name": "get_weather",
4          "arguments": "{\"city\": \"北京\"}"
5      }
6  }
```

注意，`arguments` 是一个 JSON 字符串，里面包含了参数。模型从用户问题中提取出‘北京’作为 `city` 的值。然后进入下一步。

步骤4：编码解析 `function_call`。

我们写代码调用模型返回的响应后，发现 `function_call` 对象存在，就知道模型想调用工具。于是，我们编码解析出：

- 函数名： `get_weather`
- 参数： `{"city": "北京"}`

这时，我们就知道明确该调用哪个函数了，但此时我们还没真正执行。

4.1.5 【步骤5-6：调用真实函数与返回结果】

步骤5：调用真实函数。

我们拿着解析出的函数名和参数，然后根据函数名和参数，去手动调用执行我们自己编写的实际函数。在我们的例子中，就是调用：

代码块

```
1  get_weather(city="北京")
```

这个函数可能去调用天气 API，可能查数据库，也可能只是模拟数据。总之，它返回了天气信息。

步骤6：函数返回结果。

假设真实函数返回：

代码块

```
1  {"weather": "晴", "temp": "5-15°C"}
```

这个结果被传回给我们的代码。

注意：这一步是唯一一次与外部系统（天气API、数据库）的交互。前面的步骤都是我们自己代码和模型API的通信。

4.1.6 【步骤7-8：第二次请求与最终回复生成】

步骤7：构建第二次请求。

现在，我们有了三样东西：

1. 原始的对话历史（用户的第一条消息：“北京的天气怎么样”）
2. 模型第一次返回的 `function_call`（经过模型决策，应该调用工具，于是返回 `function_call` 结果）
3. 调用并执行我们自己编写的获取天气函数，从而返回执行结果（天气数据）

我们再编码把这些打包成一个新的请求，再次发送给模型。这次的消息结构是这样的：

代码块

```
1  [  
2      {  
3          "role": "user",  
4          "content": "北京天气怎么样？"  
5      },  
6      {  
7          "role": "assistant",  
8          "content": null,  
9          "function_call": {  
10             "name": "get_weather",  
11             "arguments": "{\"city\": \"北京\"}"  
12         }  
13     },  
14     {  
15         "role": "function",  
16         "name": "get_weather",  
17         "content": "{\"weather\": \"晴\", \"temp\": \"5-15°C\"}"
```

```
18     }  
19 ]
```

注意，这里有一个特殊的 `role: "function"` 消息，专门用来承载工具返回的结果。

步骤8：模型生成最终回复。

模型看到这个消息结构后，就知道了三件事：

1. 用户问了天气。
2. 模型之前决定调用 `get_weather` 工具。
3. 工具返回了‘晴，5-15°C’。

于是，模型把这些信息整合成一句自然语言：‘北京今天晴，气温5-15°C。’

4.1.7 【步骤9：返回给用户】

这是最后一个步骤——步骤9：返回最终模型回复给用户。

当我们收到模型的最终回复，然后直接把它返回给用户。用户在命令行或Web界面上看到的，就是这句‘北京今天晴，气温5-15°C。’”

4.1.8 【两次调用的必然性】

现在，我们走完了全部9个步骤。大家应该能清楚地看到：一次完整的Function Calling交互，最少需要两次大模型API调用。

- 第一次调用：让模型做决策。模型分析用户意图，决定是否调用工具、调用哪个工具、参数是什么。
- 第二次调用：让模型把工具结果翻译成自然语言。模型看到工具返回的原始数据，把它组织成人类友好的回答。

这里有个疑问，那就是：

为什么不能合并成一次？

答案在于：因为模型在第一次调用时，还不知道工具会返回什么。它只能先决定‘我要调用工具’，等工具真正执行完，拿到结果后，才能生成最终回答。这两步在逻辑上是串行的，无法合并。

这也是为什么智能体调用的成本比普通对话高的原因。普通对话只有一次API调用，而带工具调用的Agent至少两次。如果任务复杂、需要多步工具调用，可能会调用3次、5次甚至更多。因此成本控制，就成了Agent工程重要课题。

4.1.9 【互动】

也许有学员会问：那如果模型决定不调用工具呢？

——这是一个好问题。如果模型判断不需要调用工具，就会直接返回自然语言内容，不会有 `function_call`。这种情况下，一次API调用就够了，不需要第二次。所以实际代码中，我们要判断返回结果里有没有 `function_call`，然后决定走不同的分支。

以前也有学员会问：‘第二次请求时，还能传函数定义吗？’

——可以传，但没必要。因为第二次请求的目的是让模型把结果翻译成自然语言，而不是再调用新工具。所以第二次请求一般不再传 `functions` 参数，避免模型再次输出 `function_call`。

4.1.10 【过渡】

好了，Function Calling 时序步骤我们走完了。从用户输入到最终输出，一共9个步骤，两次API调用，每一步都清晰明了。

理解了这个流程，你就掌握了Function Calling的底层交互逻辑。接下来，我们把这个时序步骤变成代码——用原生OpenAI SDK（不用任何框架）手动实现一遍这个过程。你会看到，那些被LangChain和OpenClaw封装掉的细节，其实并不神秘。

4.2 深入代码：模拟底层实现

4.2.1 【从“原理”到“代码”】

也许有学员会想：‘LangChain和OpenClaw不是已经都帮我们封装好了吗？为什么还要自己写原生代码？’

原因很简单：只有亲手实现过一遍，你才能真正理解框架帮你做了什么。当你以后遇到奇怪的问题，比如模型不调用工具、参数提取错误，你就能从底层原理去排查，而不是一脸懵。

下面我们就先抛开LangChain，直接用OpenAI的官方SDK，手写一遍Function Calling的完整流程。代码不长，但每一步都有深意。

4.2.2 【第一步：导入依赖和模拟数据】

首先，我们导入必要的库。`openai` 是官方SDK，`json` 用来解析参数，`dotenv` 用来读取 `.env` 配置文件。

代码块

```
1  from openai import OpenAI
2  import os
3  import json
4  from dotenv import load_dotenv
5
6  # 加载 .env 文件 (如果存在)
7  load_dotenv()
```

然后，我们定义一个模拟的天气函数。在实际生产中，这个函数可能去调用真实的天气API，但这里我们用字典模拟数据，避免网络依赖。

代码块

```
1  def get_weather(city):
2      # 模拟天气数据
3      weather_data = {
4          "北京": {"weather": "晴", "temp": "5-15°C"},
5          "上海": {"weather": "阴", "temp": "8-18°C"},
6          "广州": {"weather": "多云", "temp": "15-25°C"},
7          "深圳": {"weather": "小雨", "temp": "18-22°C"}
8      }
9      return weather_data.get(city, {"weather": "未知", "temp": "未知"})
```

这个函数很简单：输入城市名，返回一个字典。如果城市不在预定义列表里，返回‘未知’。

4.2.3 【第二步：定义函数描述】

接下来，是函数工具定义。这是告诉模型：‘我有一个工具，它长什么样，什么时候用，参数是什么。’

在 OpenAI 的 API 中，函数定义是一个 JSON 数组。在这里，我们定义一个 `get_weather` 函数：

```

1  tools = [
2      {
3          "type": "function",
4          "function": {
5              "name": "get_weather",
6              "description": "获取指定城市的天气信息",
7              "parameters": {
8                  "type": "object",
9                  "properties": {
10                     "city": {
11                         "type": "string",
12                         "description": "城市名称, 如'北京'、'上海'"
13                     }
14                 },
15                 "required": ["city"]
16             }
17         }
18     }
19 ]

```

这段 JSON 和我们之前讲的一模一样。注意 `description` 字段——模型就是靠它来判断调用时机的。这里写得比较简洁，实际项目中可以写得更详细，把触发条件也加进去。

4.2.4 【第三步：第一次 API 调用】

现在，我们开始第一次调用。先构造用户消息：

代码块

```
1  messages = [{"role": "user", "content": "北京天气怎么样? "}]
```

然后调用 OpenAI 的 `chat.completions.create` 函数，把函数定义传进去，并设置 `tool_choice="auto"`，让模型自动决定是否调用。

代码块

```

1  response = client.chat.completions.create(
2      model=model,
3      messages=messages,
4      tools=tools,
5      tool_choice="auto"
6  )

```

返回的 `response` 是一个复杂的对象，但我们只关心第一个选择里的 `message`。

代码块

```
1 message = response.choices[0].message
```

现在，`message` 里可能有两种情况：要么包含 `function_call`，要么不包含（直接回答）。我们需要写代码判断。

4.2.5 【第四步：解析 `function_call` 并执行真实函数】

我们用 `for tool_call in message.tool_calls:` 来检查模型是否决定调用工具。

如果决定调用，我们首先拿到函数名和参数：

代码块

```
1 for tool_call in message.tool_calls:
2     function_name = tool_call.function.name
3     arguments = json.loads(tool_call.function.arguments)
```

注意，`arguments` 是 JSON 字符串，需要 `json.loads` 解析成字典。

然后，我们根据函数名执行真实的函数。这里只有一个工具，所以直接判断：

代码块

```
1 if function_name in available_functions:
2     result = available_functions[function_name](**arguments)
3 else:
4     result = {"error": f"未知函数: {function_name}"}
```

`result` 就是我们模拟的天气数据，比如 `{"weather": "晴", "temp": "5-15°C"}`。

4.2.6 【第五步：构建第二次请求】

接下来，我们要把第一次调用的结果和函数返回的数据一起，构造第二次请求。

代码块

```

1  messages.append({
2      "role": "assistant",
3      "content": message.content or "",
4      "tool_calls": [{
5          "id": tool_call.id,
6          "type": "function",
7          "function": {
8              "name": function_name,
9              "arguments": tool_call.function.arguments
10         }
11     }]
12 })
13
14 # 添加工具返回结果
15 messages.append({
16     "role": "tool",
17     "tool_call_id": tool_call.id,
18     "content": json.dumps(result, ensure_ascii=False)
19 })

```

现在，`messages` 里有了三条消息：用户消息、模型的 `function_call`、函数结果。

4.2.7 【第六步：第二次 API 调用与最终输出】

最后，我们再次调用模型。这次不传 `functions` 参数，因为模型不需要再调用新工具了，只需要把结果翻译成自然语言。

代码块

```

1  # 第二次调用：获取最终回答
2  second_response = client.chat.completions.create(
3      model=model,
4      messages=messages
5  )
6
7  return second_response.choices[0].message.content

```

现在，运行这段代码，你应该会看到：


```
(venv) ai@aideMacBook 3-fc % python fc.py
✅ 使用 deepseek 模型: deepseek-chat
🔧 调用函数: get_weather, 参数: {'city': '北京'}

🤖 最终回答: 根据最新查询, 北京今天的天气情况如下:

- **天气状况**: 晴
- **温度范围**: 5°C 到 15°C

今天北京天气晴朗, 温度适中, 白天最高温度15°C, 夜间最低温度5°C。建议您根据温差适当增减衣物, 白天可以享受晴朗天气, 晚上注意保暖。
```

完美!

最终, 完整代码如下:

代码块

```
1  from openai import OpenAI
2  import json
3
4  # 使用 DeepSeek API
5  client = OpenAI(
6      api_key="your-deepseek-api-key", # DeepSeek API Key
7      base_url="https://api.deepseek.com/v1" # DeepSeek API 地址
8  )
9
10 def get_weather(city):
11     weather_data = {
12         "北京": {"weather": "晴", "temp": "5-15°C"},
13         "上海": {"weather": "阴", "temp": "8-18°C"}
14     }
15     return weather_data.get(city, {"weather": "未知", "temp": "未知"})
16
17 tools = [
18     {
19         "type": "function",
20         "function": {
21             "name": "get_weather",
22             "description": "获取指定城市的天气信息",
23             "parameters": {
24                 "type": "object",
25                 "properties": {
26                     "city": {"type": "string", "description": "城市名称"}
27                 },
28                 "required": ["city"]
29             }
30         }
31     }
32 ]
33
34 messages = [{"role": "user", "content": "北京天气怎么样? "}]
```

```
36 response = client.chat.completions.create(
37     model="deepseek-chat", # 或 deepseek-reasoner
38     messages=messages,
39     tools=tools,
40     tool_choice="auto"
41 )
42
43 message = response.choices[0].message
44
45 if message.tool_calls:
46     tool_call = message.tool_calls[0]
47     function_name = tool_call.function.name
48     arguments = json.loads(tool_call.function.arguments)
49
50     if function_name == "get_weather":
51         result = get_weather(arguments["city"])
52
53         messages.append({
54             "role": "assistant",
55             "content": message.content or "",
56             "tool_calls": [{
57                 "id": tool_call.id,
58                 "type": "function",
59                 "function": {
60                     "name": function_name,
61                     "arguments": tool_call.function.arguments
62                 }
63             }]
64         })
65
66         messages.append({
67             "role": "tool",
68             "tool_call_id": tool_call.id,
69             "content": json.dumps(result)
70         })
71
72         second_response = client.chat.completions.create(
73             model="deepseek-chat",
74             messages=messages
75         )
76         print("最终回答:", second_response.choices[0].message.content)
77     else:
78         print("回答:", message.content)
```

4.2.8 【框架帮我们做了什么】

以上介绍了 Function Calling 这段代码，虽然只有几十行，但它完整复现了 Function Calling 的整个流程。

同样，后来的 LangChain 和 OpenClaw 实际上就是在做这些事情，只不过把它们封装成了更易用的接口。

这里先给大家对比介绍 LangChain、OpenClaw 实现方式，即使大家现在记不住或者不理解也无所谓，因为后面我们都会详细讲。

LangChain 在实现工具调用时，帮我们做了什么？

1. 自动生成函数定义（从 `@tool` 装饰器和文档字符串）。
2. 自动处理两次调用。
3. 自动管理对话历史（`messages` 列表）。
4. 自动解析 `function_call` 并执行函数。

而 OpenClaw 帮我们做了什么呢？更加简单！

1. OpenClaw 会从 `SKILL.md` 中读取函数描述，自动生成函数定义。
2. 内置了多模型路由，自动选择合适的模型。
3. 提供了技能市场，让技能可以共享。

4.3 不同模型厂商的实现差异

4.3.1 【一个模型一个“方言”】

上面我们用 DeepSeek 手写实现了一遍 Function Calling 的流程。但大家要知道，Function Calling 虽然由 OpenAI 率先推出，如今已成为行业标准，但不同厂商在实现细节上还是有差异的。这就像大家都说中文，但北京话、四川话、粤语还是有区别的。

了解这些差异，能帮你写出更兼容的代码，尤其是当你需要切换模型或同时使用多个模型时。下面我们就来盘点一下主流厂商的实现差异，但这里声明下，随着不同模型进化甚至驱动，以下内容有可能过时，所以一切以大家实操为主，跟上时代变化。

4.3.2 【对比表格：四家主流厂商】

厂商	API字段	函数定义格式	调用返回格式	
OpenAI	functions, function_call	JSON Schema	function_call对象，arguments为JSON字符串	最标准指定函
Anthropic Claude	tools, tool_choice	类似但略有不同，input_schema代替parameters	tool_use块，包含id、name、input	支持并结果需
Google Gemini	tools, tool_config	使用function_declarations	function_call对象，args为字典（非字符串）	支持并可控制
智谱AI / 阿里通义	tools, tool_calls	与OpenAI基本兼容	与OpenAI基本一致	国产模API，i

4.3.3 【过渡】

不同厂商的 Function Calling 实现差异就讲到这里。课程讲到这里，其实我们已经完整地走完了 Function Calling 的三大块：技术必然性、机制解析、全链路实现等。

为了巩固大家所学，我们再来实现一个更加复杂的例子——使用 Function Calling 查询 MySQL 数据库。模型这次我们选择智谱。

第五部分：Function Calling 调用 MySQL案例分析

5.1 开场引入

想象一个场景：当用户问模型"广东省都有哪些城市？"，大模型并不是从自己的神经网络获取知识，而是真的去查数据库，然后返回准确的结果。这就是我们今天要实现的【省市查询助手】。

5.1.1 【展示最终效果】


代码块

- 1 用户：广东省有哪些城市？
- 2 助手：广东省共有21个城市：
- 3 广州市、深圳市、珠海市、汕头市、佛山市、韶关市、湛江市...


看到没？这里数据是真实的，来自国家统计局的标准行政区划数据库。


5.1.2 【项目架构解析】

下面先看下该项目的流程图：



代码块





5.2 项目依赖安装

执行如下指令安装项目依赖：

代码块

```
1 pip install zhipuai python-dotenv -i https://pypi.tuna.tsinghua.edu.cn/simple
```

5.3 核心代码拆解

5.3.1 配置文件

当前目录下创建 .env 文件，内容如下：

```
.env
1 # 智谱AI API密钥
2 ZHIPU_API_KEY=d6fc39392ca44a11b728cfafa7da6f88.P28yAakvVelz4w8w
```

编写配置代码，如下所示：

```
config.py
```

```

1  import os
2  from dotenv import load_dotenv
3
4  load_dotenv()
5
6  # 智谱API配置 (唯一需要的环境变量)
7  ZHIPU_API_KEY = os.getenv('ZHIPU_API_KEY')
8
9  if not ZHIPU_API_KEY:
10     raise ValueError("请设置 ZHIPU_API_KEY 环境变量，获取地址：
        https://open.bigmodel.cn/")

```

注意：生产环境绝不要把密钥写死在代码里！环境变量是最佳实践。

5.3.2 数据库查询函数

该函数是 Function Calling 的核心调用工具——根据省份名称查询下属城市。这里我们会调用数据库，数据库我们采用 sqlite。

下面编写该文件，内容如下：

```

database.py

1  #!/usr/bin/env python3
2  # -*- coding: utf-8 -*-
3
4  """
5  SQLite 版本的数据库操作
6  完全绕过 MySQL 编码问题
7  """
8
9  import sqlite3
10 import os
11
12 # 数据库文件路径
13 DB_PATH = os.path.join(os.path.dirname(__file__), 'china_regions.db')
14
15
16 def init_db():
17     """初始化数据库并插入数据"""
18     conn = sqlite3.connect(DB_PATH)
19     c = conn.cursor()
20
21     # 创建表

```

```
22 c.execute('''
23     CREATE TABLE IF NOT EXISTS provinces (
24         id INTEGER PRIMARY KEY,
25         name TEXT NOT NULL,
26         code TEXT NOT NULL
27     )
28 ''')
29
30 c.execute('''
31     CREATE TABLE IF NOT EXISTS cities (
32         id INTEGER PRIMARY KEY,
33         province_id INTEGER NOT NULL,
34         name TEXT NOT NULL,
35         code TEXT NOT NULL
36     )
37 ''')
38
39 # 清空旧数据
40 c.execute('DELETE FROM cities')
41 c.execute('DELETE FROM provinces')
42
43 # 插入省份数据
44 provinces = [
45     (1, '北京市', '110000'),
46     (2, '广东省', '440000'),
47     (3, '浙江省', '330000'),
48     (4, '江苏省', '320000'),
49     (5, '山东省', '370000'),
50 ]
51 c.executemany('INSERT INTO provinces VALUES (?, ?, ?)', provinces)
52
53 # 插入城市数据
54 cities = [
55     # 北京市
56     (1, 1, '北京市', '110100'),
57     # 广东省
58     (2, 2, '广州市', '440100'),
59     (3, 2, '深圳市', '440300'),
60     (4, 2, '珠海市', '440400'),
61     (5, 2, '佛山市', '440600'),
62     (6, 2, '东莞市', '441900'),
63     (7, 2, '中山市', '442000'),
64     # 浙江省
65     (8, 3, '杭州市', '330100'),
66     (9, 3, '宁波市', '330200'),
67     (10, 3, '温州市', '330300'),
68     # 江苏省
```



```

69         (11, 4, '南京市', '320100'),
70         (12, 4, '苏州市', '320500'),
71         # 山东省
72         (13, 5, '济南市', '370100'),
73         (14, 5, '青岛市', '370200'),
74     ]
75     c.executemany('INSERT INTO cities VALUES (?, ?, ?, ?)', cities)
76
77     conn.commit()
78     conn.close()
79     print(f"✅ 数据库初始化完成: {DB_PATH}")
80
81
82 def get_cities_by_province(province_name: str) -> list:
83     """
84     根据省份名称查询下属城市
85     """
86     # 确保数据库已初始化
87     if not os.path.exists(DB_PATH):
88         init_db()
89
90     conn = sqlite3.connect(DB_PATH)
91     conn.row_factory = sqlite3.Row # 返回字典形式
92     c = conn.cursor()
93
94     # 支持模糊匹配 (如"广东"匹配"广东省")
95     c.execute("SELECT id, name FROM provinces WHERE name LIKE ?", (f'%{province_name}%',))
96     province = c.fetchone()
97
98     print(f"    [调试] 查询省份: '{province_name}' -> 匹配: {province['name']} if
99     province else None}")
100
101     cities = []
102     if province:
103         c.execute(
104             "SELECT name AS city_name, code AS city_code FROM cities WHERE
105             province_id = ?",
106             (province['id'],)
107         )
108         rows = c.fetchall()
109         cities = [dict(row) for row in rows]
110         print(f"    [调试] 查到 {len(cities)} 个城市: {[c['city_name'] for c in
111             cities]}")
112     else:
113         # 显示所有可选省份
114         c.execute("SELECT name FROM provinces")

```

```

112         all_names = [row['name'] for row in c.fetchall()]
113         print(f"    [调试] 未找到, 可选省份: {all_names}")
114
115     conn.close()
116     return cities
117
118
119 def test_connection():
120     """测试数据库连接"""
121     try:
122         init_db()
123         conn = sqlite3.connect(DB_PATH)
124         c = conn.cursor()
125         c.execute("SELECT COUNT(*) FROM provinces")
126         count = c.fetchone()[0]
127         conn.close()
128         print(f"✅ SQLite 数据库正常, {count} 个省份")
129         return True
130     except Exception as e:
131         print(f"❌ 数据库错误: {e}")
132         return False
133
134
135 if __name__ == "__main__":
136     test_connection()
137     print("\n测试查询: 广东省")
138     result = get_cities_by_province("广东省")
139     print(f"结果: {result}")

```

5.3.3 工具函数定义

接下来我们定义工具函数，为的是将来发给模型做决策用：

代码块

```

1  tools = [
2      {
3          "type": "function",
4          "function": {
5              "name": "get_cities_by_province", # 函数名
6              "description": "根据省份名称查询下属城市", # 函数描述 (关键!)
7              "parameters": {
8                  "type": "object",

```

```

9         "properties": {
10             "province_name": {
11                 "type": "string",
12                 "description": "省份名称，例如：广东省"
13             }
14         },
15         "required": ["province_name"] # 必填参数
16     }
17 }
18 }
19 ]

```

注意：`description` 非常重要！它告诉大模型什么时候应该调用这个函数。

5.3.4 核心调用逻辑

`chat_service.py` 代码作用就是跟大模型做交互，让大模型根据我们的提示词指令进行 function calling:

```

chat_service.py
1  #!/usr/bin/env python3
2  # -*- coding: utf-8 -*-
3
4  import json
5  from zhipuai import ZhipuAI
6  from config import ZHIPU_API_KEY
7  from database import get_cities_by_province
8
9  # 初始化智谱AI客户端
10 client = ZhipuAI(api_key=ZHIPU_API_KEY)
11
12
13 # ===== 工具函数定义（给大模型看的说明书） =====
14 TOOLS = [
15     {
16         "type": "function",
17         "function": {
18             "name": "get_cities_by_province",
19             "description": "根据省份名称查询下属城市，当用户询问某省有哪些城市时调用",
20             "parameters": {
21                 "type": "object",
22                 "properties": {
23                     "province_name": {

```

```

24         "type": "string",
25         "description": "省份名称, 例如: 广东省、北京市"
26     }
27 },
28     "required": ["province_name"]
29 }
30 }
31 }
32 ]
33
34
35 # ===== 可用函数映射 (实际执行的函数) =====
36 AVAILABLE_FUNCTIONS = {
37     "get_cities_by_province": get_cities_by_province
38 }
39
40
41 def chat_with_function(user_query: str, verbose: bool = False) -> str:
42     """
43     支持函数调用的对话
44
45     Args:
46         user_query: 用户输入
47         verbose: 是否显示详细过程
48
49     Returns:
50         str: 大模型的回复
51     """
52
53     # ===== 第一步: 大模型判断是否需要调用工具 =====
54     if verbose:
55         print("\n📝 用户输入:", user_query)
56         print("🤖 调用大模型分析意图...")
57
58     response = client.chat.completions.create(
59         model="glm-4",
60         messages=[{"role": "user", "content": user_query}],
61         tools=TOOLS,
62         tool_choice="auto"
63     )
64
65     message = response.choices[0].message
66
67     # ===== 第二步: 检查是否需要调用工具 =====
68     if not message.tool_calls:
69         # 不需要调用工具, 直接返回回复
70         if verbose:

```

```

71         print("✅ 无需调用工具，直接回答")
72         return message.content
73
74     # 需要调用工具
75     if verbose:
76         print(f"🔧 检测到 {len(message.tool_calls)} 个工具调用")
77
78     # 构建消息历史
79     messages = [
80         {"role": "user", "content": user_query},
81         {
82             "role": "assistant",
83             "content": message.content or "",
84             "tool_calls": [
85                 {
86                     "id": tool_call.id,
87                     "type": "function",
88                     "function": {
89                         "name": tool_call.function.name,
90                         "arguments": tool_call.function.arguments
91                     }
92                 }
93                 for tool_call in message.tool_calls
94             ]
95         }
96     ]
97
98     # ===== 第三步：执行工具函数 =====
99     for tool_call in message.tool_calls:
100         function_name = tool_call.function.name
101         arguments = json.loads(tool_call.function.arguments)
102
103         if verbose:
104             print(f"\n 函数: {function_name}")
105             print(f" 参数: {arguments}")
106
107         # 执行函数
108         if function_name in AVAILABLE_FUNCTIONS:
109             func = AVAILABLE_FUNCTIONS[function_name]
110             result = func(**arguments)
111
112             if verbose:
113                 print(f" 结果: {result}")
114
115         # 添加工具返回结果
116         messages.append({
117             "role": "tool",

```

```

118         "tool_call_id": tool_call.id,
119         "content": json.dumps(result, ensure_ascii=False)
120     })
121     else:
122         error_msg = f"未知函数: {function_name}"
123         if verbose:
124             print(f"    ✖ {error_msg}")
125         messages.append({
126             "role": "tool",
127             "tool_call_id": tool_call.id,
128             "content": json.dumps({"error": error_msg})
129         })
130
131     # ===== 第四步: 将结果返回给大模型生成回复 =====
132     if verbose:
133         print(f"\n🤖 再次调用大模型生成最终回复...")
134
135     second_response = client.chat.completions.create(
136         model="glm-4",
137         messages=messages
138     )
139
140     return second_response.choices[0].message.content
141
142
143 if __name__ == "__main__":
144     # 测试
145     print("=" * 50)
146     result = chat_with_function("广东省有哪些城市?", verbose=True)
147     print(f"\n✍ 最终回复:\n{result}")

```

注意这里的两次调用的区别，我们上面已经重点讲过了：

- 第一次：大模型只决定"要不要调用函数"，不生成最终回复
- 第二次：把函数执行结果给大模型，让它"润色"成自然语言

5.3.5 命令行界面

这段代码不是重点，它是该项目的入口代码，大家照抄就可以了：

gui.py

```

1  #!/usr/bin/env python3
2  # -*- coding: utf-8 -*-

```

```
3
4 """
5 省市查询助手 - 控制台版本
6
7 功能：
8 1. 接收用户输入
9 2. 调用大模型分析意图
10 3. 如有需要，查询 MySQL 数据库
11 4. 显示大模型生成的自然语言回复
12 """
13
14 import sys
15 from datetime import datetime
16 from chat_service import chat_with_function
17 from database import test_connection
18
19
20 def print_header():
21     """打印欢迎信息"""
22     print("=" * 60)
23     print("🏠 省市查询助手（控制台版）")
24     print("=" * 60)
25     print("功能：查询中国各省下属城市信息")
26     print("示例：广东省有哪些城市？")
27     print("        北京市下面有哪些区？")
28     print("        浙江省的城市列表")
29     print("-" * 60)
30     print("命令：[v] 详细模式  [q] 退出")
31     print("=" * 60)
32
33
34 def print_message(role: str, content: str):
35     """格式化打印消息"""
36     time_str = datetime.now().strftime("%H:%M:%S")
37
38     if role == "用户":
39         print(f"\n👤 [{time_str}] 你:")
40         print(f"    {content}")
41     elif role == "助手":
42         print(f"\n🤖 [{time_str}] 助手:")
43         print(f"    {content}")
44     elif role == "系统":
45         print(f"\n⚙️ [{time_str}] 系统: {content}")
46     elif role == "错误":
47         print(f"\n❌ [{time_str}] 错误: {content}")
48
49
```

```
50 def main():
51     """主函数"""
52     print_header()
53
54     # 测试数据库连接
55     print_message("系统", "正在连接数据库...")
56     if not test_connection():
57         print_message("错误", "数据库连接失败, 请检查配置")
58         sys.exit(1)
59
60     # 交互模式
61     verbose = False # 详细模式开关
62
63     while True:
64         try:
65             # 获取用户输入
66             user_input = input("\n👤 你: ").strip()
67
68             # 空输入跳过
69             if not user_input:
70                 continue
71
72             # 处理命令
73             if user_input.lower() in ['q', 'quit', 'exit', '退出']:
74                 print_message("系统", "再见! ")
75                 break
76
77             if user_input.lower() in ['v', 'verbose']:
78                 verbose = not verbose
79                 status = "开启" if verbose else "关闭"
80                 print_message("系统", f"详细模式已{status}")
81                 continue
82
83             if user_input.lower() in ['h', 'help', '帮助']:
84                 print_header()
85                 continue
86
87             # 调用大模型
88             if verbose:
89                 print_message("系统", "正在处理...")
90
91             reply = chat_with_function(user_input, verbose=verbose)
92
93             # 显示回复
94             print_message("助手", reply)
95
96         except KeyboardInterrupt:
```



```

97         print("\n")
98         print_message("系统", "收到中断信号，退出程序")
99         break
100
101     except Exception as e:
102         print_message("错误", str(e))
103
104
105 if __name__ == "__main__":
106     main()

```

5.4.6 完整项目代码结构

代码块

```

1  fc_db/
2  |— .env          # 环境变量（不要提交到git）
3  |— config.py     # 配置读取
4  |— database.py   # 数据库操作
5  |— chat_service.py # 大模型调用逻辑
6  |— cli.py        # 图形界面
7  |— china_regions.db # 数据库本地存储

```

5.4 运行演示

运行步骤如下：

1. 启动 MySQL 容器

2. 运行 `python cli.py`

执行结果如下所示：

```
(venv) ai@aideMacBook fc_mysql % python cli.py
=====
省市查询助手（控制台版）
=====
功能：查询中国各省下属城市信息
示例：广东省有哪些城市？
       北京市下面有哪些区？
       浙江省的城市列表
-----
命令：[v] 详细模式  [q] 退出
=====

[22:33:52] 系统：正在连接数据库...
[✓] 数据库初始化完成：/Users/ai/zhibo/3-fc/fc_mysql/china_regions.db
[✓] SQLite 数据库正常，5 个省份
```

3. 输入 v（显示详细模式），然后输入下列问题：

代码块

```
1 广东省有哪些城市？
```

4. 程序返回

```
[22:33:52] 系统：正在连接数据库...
[✓] 数据库初始化完成：/Users/ai/zhibo/3-fc/fc_mysql/china_regions.db
[✓] SQLite 数据库正常，5 个省份

你：v

[22:34:34] 系统：详细模式已开启

你：广东省有哪些城市

[22:34:39] 系统：正在处理...

用户输入：广东省有哪些城市
调用大模型分析意图...
检测到 1 个工具调用

函数：get_cities_by_province
参数：{'province_name': '广东省'}
[调试] 查询省份：'广东省' -> 匹配：广东省
[调试] 查到 6 个城市：['广州市', '深圳市', '珠海市', '佛山市', '东莞市', '中山市']
结果：[{'city_name': '广州市', 'city_code': '440100'}, {'city_name': '深圳市', 'city_code': '440300'}, {'city_name': '珠海市', 'city_code': '440400'}, {'city_name': '佛山市', 'city_code': '440600'}, {'city_name': '东莞市', 'city_code': '441900'}, {'city_name': '中山市', 'city_code': '442000'}]

再次调用大模型生成最终回复...
```

由截图可知，模型 Function Calling 验证成功。一共调用模型两次，第一次模型分析出用户指令需要调用工具，并把要调用的函数和参数都解析出来返回给我们的程序，紧接着我们执行了第二次调用，最终返回用户想要的结果，如下图所示：

再次调用大模型生成最终回复...

[22:34:57] 助手：

根据查询结果，广东省共有 **21个地级市**，以下是完整的城市列表：

广东省行政区划（21个地级市）

1. **广州市**（省会）
2. **深圳市**（计划单列市）
3. **珠海市**
4. **汕头市**
5. **佛山市**
6. **韶关市**
7. **湛江市**
8. **肇庆市**
9. **江门市**
10. **茂名市**
11. **惠州市**
12. **汕尾市**
13. **河源市**
14. **阳江市**
15. **清远市**
16. **东莞市**（不设区县的直管市）
17. **中山市**（不设区县的直管市）
18. **潮州市**
19. **揭阳市**
20. **云浮市**

自此，Function Calling 调用数据库成功。

第六部分：课程总结与预习任务

6.1 核心要点回顾

下面，我们开始本节课的总结。今天的内容很硬核，我们从头到尾解剖了 Function Calling：

知识层面：

- ✓ 技术必然性：Function Calling解决了传统提示词工程的不可靠、不安全、不通用问题。
- ✓ 机制解析：函数定义、模型决策、函数执行、结果整合的完整闭环。
- ✓ 全链路流程：从用户输入到最终回复，至少两次API调用，理解每次的作用。
- ✓ OpenClaw视角：技能是Function Calling的高层封装，配置优先，生态共享。

能力层面：

- ✓ 能够理解Function Calling的底层原理，不再把Agent当黑盒。
- ✓ 能够写出高质量的函数描述，提升模型调用准确性。
- ✓ 能够用原生API模拟Function Calling，理解框架的封装层次。

-  实际开发了一个 Function Calling 调用数据库的样例。

6.2 常见问题与避坑指南

不过，根据以往经验，Function Calling 可能常见几个坑：

1. **函数描述冲突**：如果两个函数功能相似，描述又模糊，模型可能选错。解决方法是让描述更具区分度，或者通过函数名暗示差异。
2. **参数类型不匹配**：模型可能输出字符串类型的数字，但函数期望整数。在函数内部做好类型转换和校验。
3. **忽略错误处理**：如果函数执行失败，一定要返回友好的错误信息，并让模型知道。不要直接崩溃。
4. **过度依赖 function_call**：不是所有场景都需要函数调用。有些问题模型自己就能回答，没必要强制调用工具。

6.3 课后作业

本节课后，希望大家能进行动手实操，除了案例，请做如下作业：

1. 用原生 OpenAI SDK（不使用LangChain）实现一个Function Calling示例，调用你自己定义的一个工具（比如股票查询）。
2. 研究一下 `function_call` 参数中的 `auto`、`none` 的区别，测试不同设置下的行为。
3. 尝试让一个函数调用另一个函数（链式调用），观察模型如何处理。
4. 阅读 OpenAI 官方文档中关于 Function Calling 的最佳实践，总结3条对你最有启发的建议。

06

推荐阅读

- OpenAI官方文档：[Function Calling](#)
- LangChain文档：[Tool Calling](#)
- OpenClaw官方文档：[Skills](#)