

L4

模型微调与 私有化大模型

L4 模型微调与私有化大模型 · 课程安排



模块一 基础与认知	模块二 数据与微调	模块三 量化与对齐	模块四 部署与工程化	模块五 集成与交付
1 大模型开发基础 与项目导入	2 微调数据 准备与生成	5 模型量化 方法与实践	7 推理引擎 部署实战	9 系统集成 与智能体
	3 LoRA微调 方法与实践	6 QLoRA微调 对齐与量化评估 ★ M2: 量化模型+性能对比	8 Docker容器化 API工程化 ★ M3: 服务可调用 +Docker	10 智能编程 项目交付 ★ M4: 完整系统+技术文档
	4 模型评估、数据 优化 ★ M1: 微调模型+评估报告			

10讲 · 5大模块 · 4个里程碑 · 40+练习 · 综合实战项目贯穿全程

1.大模型开发基础

1. 开源大模型

什么是大模型？



通常指参数规模达到十亿级以上的深度学习模型，具备较强的语言理解与生成能力。

参数规模大

- 典型范围：数十亿到数千亿（10B ~ 100B）
- 参数示例：GPT-3（175B） Llama 3（8B / 70B） Qwen 系列（0.5B – 72B）

训练数据多

- 通常使用数百GB到数TB级
- 语料数据来源：网页、书籍、代码、论文等。

训练成本高

- GPT-3：约为 450 万--500 万美元。GPT-4：估计在 2000 万--3000 万美元。
- LLaMA 系列（7B、13B、30B）：训练成本通常在数十万到上百万美元。

模型能力强

- 语言理解与生成，推理与问题求解，多任务泛化能力，多模态扩展能力（文本+图像+语音）

类别	主要功能与任务说明	代表模型
通用语言模型	负责文本理解、生成、摘要、翻译、推理等通用语言任务；是所有下游应用的核心基座。	GPT、LLaMA、Qwen
多模态模型	能处理并融合多种模态（文字、图像、语音、视频），实现跨模态理解与生成。	GPT-4o、Qwen-VL
代码模型	专注编程相关任务，如代码生成、补全、调试与逻辑推理。	CodeLlama、DeepSeek-Coder、Qwen-Coder
对话指令模型	用于自然语言交互，具备上下文理解和指令执行能力，常用于客服或智能助手。	ChatGPT、Qwen-Chat
领域专用模型	针对医疗、法律、金融、教育等特定领域进行定制微调，具备专业知识。	MedGPT、LawGPT、FinGPT

闭源模型局限性



- **缺乏灵活性**：无法定制，限制业务创新与优化。
- **依赖供应商**：受制于第三方，存在价格波动和服务中断风险。
- **隐私风险**：数据需上传外部，可能不符合法规要求。
- **成本高昂**：按量计费，长期使用成本较高。

开源大模型的优势



- **可定制**：灵活调整，满足业务需求。
- **低成本**：减少对高费用API的依赖。
- **数据安全**：私有部署防止数据泄露，符合合规要求。

数据安全与隐私保护



- 敏感数据无需上传至公共云，避免泄露风险

业务定制化需求



- 根据企业特定场景优化模型，提升业务适配性。
- 支持个性化功能开发，增强竞争力。

性能与稳定性



- 本地部署降低延迟，提高响应速度。
- 避免公共云服务中断或性能波动的影响。


成本可控与长期价值



- 避免按使用量付费的长期成本压力。


模型性能排行榜(2026年3月)

SuperCLUE通用测评。本图展示总排行榜中各模型的总分。



开源大模型榜单（2026年3月）

SuperCLUE通用测评。本图展示开源排行榜中各模型的总分。



背景与发展

- LLaMA 是由 Meta 于 2023 年推出的开源大模型，旨在构建开放的基础模型生态。
- LLaMA 1 面向研究，LLaMA 2 支持商用，推动广泛应用。
- 2024 年的 LLaMA 3 在性能上显著提升，而 2025 年发布的 LLaMA 4 引入新架构与多模态能力，进一步强化其在开源领域的领先地位。

核心特点

- **生态最成熟**：→ 工具链完善、社区活跃，易于研究与工程应用
- **英文能力强**：→ 基于大规模英文语料训练，英文任务表现突出
- **多模态能力**：→ 支持文本与图像等多种数据形式
- **MoE架构（混合专家）**：→ 提高计算效率，减少资源消耗
- **支持长上下文**：→ 能处理更长文本和复杂对话

背景与发展

- DeepSeek 是中国新兴AI公司推出的开源模型，强调高性能与低成本。
- 自 2023 年以来持续迭代，2024 年的 V2/V3 提升了效率与能力。
- 2025 年推出的 R1 强化推理能力，同时 V3.2 持续优化，使其在推理任务中表现突出。。

核心特点

- **推理能力强**→ 擅长数学与复杂逻辑问题
- **MoE架构**：→ 提高效率并降低计算成本
- **训练成本优化**：→ 以较低资源实现较高性能
- **支持推理过程生成**：→ 输出中间思考步骤，增强可解释性
- **适合Agent系统**：→ 能处理多步骤任务

背景与发展

- Qwen 是阿里巴巴推出的开源大模型系列，自 2023 年发布以来快速发展。
- Qwen 1 奠定基础，Qwen 2 和 2.5 提升多语言与推理能力。
- 2025 年 Qwen 3 强化规模与能力，2026 年 Qwen 3.5 进一步增强多模态与智能体能力，成为中文应用的重要模型。

核心特点

- 中文能力突出 → 中文理解与生成质量高
- 多语言能力强 → 支持多语种任务
- 多模态能力 → 支持文本、图像等多种输入
- 工具调用 / **Agent**能力强 → 可调用外部工具完成复杂任务
- 指令理解能力强 → 更准确理解用户需求

系列	推荐模型	参数量	显存需求 (QLoRA)	语言优势	适合任务
LLaMA	LLaMA-2-7B	7B	16–24GB	英文强	英文对话、摘要
	LLaMA-3-8B	8B	24GB	英文强	客服、写作
DeepSeek	R1-Distill-Qwen-1.5B	1.5B	8GB	中文友好	中文对话
	R1-Distill-Qwen-7B	7B	16–24GB	中英文均衡	教育问答
Qwen	Qwen-1.5-1.8B	1.8B	8GB	中文强	中文对话
	Qwen-1.5-4B	4B	12–16GB	中英文均衡	问答、信息抽取
	Qwen-1.5-7B	7B	16–24GB	中文强	客服、知识问

2. 大模型开发应用流程

阶段	是否必须	对象	目的	常见技术
① 预训练	✔ 必须	模型基础	学语言与知识	Transformer, MoE
② 指令微调	✔ 必须	通用→任务化	理解并执行指令	SFT, LoRA, QLoRA
③ 对齐	⚙ 可选	更符合人类偏好	输出更自然安全	DPO, RLHF, IPO
④ 量化	⚙ 可选	提升效率	降显存、提速	GPTQ, AWQ, SmoothQuant
⑤ 部署推理	✔ 必须	工程落地	服务化运行	vLLM, DeepSpeed, Triton

什么是预训练模型：

- **预训练模型**指在**大规模通用语料**上经过**长时间训练**的神经网络模型。
- 它通过“**自监督学习**” (Self-supervised Learning) 掌握语言规律，而不依赖人工标注数据。
- 它相当于一个“**通才模型 (foundation model)**”，懂语言结构、语义逻辑、常识与世界知识。后续的任务微调只是让它学会“**专门技能**”。

预训练模型的核心机制

1. **目标任务**：预测下一个 token (Next-Token Prediction) $P(w_t' | w_1' w_2 \dots w_{t-1})$ ，这让模型自动学习语法、语义和上下文逻辑。
2. **自监督数据**：无需人工标注，来自网络百科、书籍、代码、论坛、论文等。例如 GPT-3 使用 570 GB 文本，Qwen 2.5 使用 3 TB 多语语料。
3. **模型架构**：基于 Transformer（解码器结构为主）。
4. **训练代价高**：通常需要上千 GPU 持续数周到数月。

定义

- **微调**是指在已预训练的大语言模型 (Base Model) 上, 利用**小规模、高质量、特定任务或领域数据**进行再训练, 让模型在特定任务中表现更好。
- 简单理解: 预训练模型是“通才”, 微调让它成为“专家”。

核心流程

- 1.**准备数据**: 清洗、去重、格式化为 `instruction / input / output`。
- 2.**加载模型**: 选择开源基座 (如 Qwen、DeepSeek、LLaMA) 。
- 3.**配置微调方法**: 常用 LoRA / QLoRA, 参数高效、显存友好。
- 4.**训练与监控**: 设置学习率、batch、epoch, 观察 Loss 曲线。
- 5.**验证与保存**: 测试输出质量, 保存 LoRA Adapter 或合并模型。

定义

- **大模型对齐 (Alignment)** 指通过算法和数据, 让模型的行为**更符合人类意图、价值观与沟通方式**的过程。
- 它解决的是模型虽然“会回答”, 但**不一定回答得合适**的问题。
- 简单理解: 微调让模型“会做事”; 对齐让模型“懂人话、懂分寸”。

为什么需要对齐

- 预训练模型只学习统计规律, **不了解人类偏好**;
- 可能输出冒犯性、危险或无关内容;
- 缺乏逻辑一致性、礼貌性和安全边界。
- 对齐的目标是让模型: ☒ 更安全 ☒ 更可信 ☒ 更自然 ☒ 更有用

典型流程 (以 DPO 为例)

- ① 收集偏好数据 (chosen/rejected)
- ② 加载参考模型 (未对齐版本)
- ③ 优化目标: 提升 chosen 概率, 压低 rejected 概率
- ④ 输出对齐后模型 (Aligned Model)

训练后模型回答更自然、安全、逻辑清晰。

核心概念

- **量化**: 将模型的高精度参数 (如 FP32 或 FP16) 转换为低比特整数 (如 INT8 或 INT4), 以显著减少模型体积和显存占用, 并提升推理速度。
- **优化**: 则是指通过算法手段让模型在运行时更高效, 常见方式包括剪枝、蒸馏、混合精度等。
- 目的: 在**尽可能保持精度的同时, 节省算力资源**, 让模型能在普通 GPU 或边缘设备上顺畅运行。

量化思路

- 在尽可能保持模型性能的前提下, 通过降低数值精度、调整计算策略或平衡参数分布, 实现模型的轻量化与高效推理。

优化常用策略

- **剪枝 (Pruning)**: 删除冗余参数或通道, 减小模型规模。
- **蒸馏 (Distillation)**: 让大模型指导小模型学习核心知识。

大模型部署简介

- 将已经训练或微调好的模型，从研发环境迁移到生产环境中，让用户或系统能够通过接口、网页或应用直接调用模型的能力。
- 部署的目标是让模型**“真正可用、可控、可扩展”**，通常包括性能优化、资源分配、安全控制与监控运维等环节。

主要目的

- **实现实时推理**：让模型能快速响应用户请求。
- **降低运行成本**：通过量化、混合精度、并行策略提升硬件利用率。
- **确保系统稳定**：在高并发场景下保持一致性能与安全性。
- **支持私有化与合规要求**：保证数据与模型在本地或安全云环境运行。

关键组成

- **推理框架**：如 vLLM（高吞吐动态批处理）、TGI（HF 官方框架）、DeepSpeed-Inference（多卡并行）、TensorRT/Triton（NVIDIA 优化）。
- **系统架构**：通常由应用层（API/前端）、推理层（模型服务）、调度层（Kubernetes）、缓存层（Redis/NVMe）、监控层（Prometheus+Grafana）构成。
- **硬件规划**：根据模型大小选择单卡或多卡部署，计算显存需求（权重+KV缓存+运行开销）。
- **性能优化**：KV缓存、PagedAttention、多卡并行等方法提高速度与效率。

3.基座大模型选型

评测基准	评测能力	负责机构	简要说明
MMLU	通用能力	University of California, Berkeley 等	覆盖57个学科，用于评估模型的知识广度与综合理解能力
GSM8K	推理能力	OpenAI	通过数学应用题评估多步推理能力
MT-Bench	对话能力	LMSYS Org	基于多轮对话任务评估聊天质量
Glue / SuperGLUE	语言能力	New York University	更高难度的语言理解任务
TruthfulQA	真实性	OpenAI	评估模型是否生成真实可靠的信息，衡量幻觉问题

评测基准	评测能力	负责机构	简要说明
C-Eval	通用能力	清华大学、上海交通大学 等	覆盖 52 个学科的中文评测集，类似 MMLU，用于评估模型综合知识与理解能力
AGIEval	推理能力	微软研究院	基于高考、公务员等考试数据，评估模型的推理与复杂问题解决能力
MT-Bench 中文版	对话能力	LMSYS 组织	多轮对话评测，结合 LLM-as-a-judge，用于评估交互质量与指令跟随能力
FlagEval	综合能力	北京智源人工智能研究院	提供统一评测平台，覆盖能力、推理、安全等多维指标，支持模型横向对比

一、明确应用场景

- **通用问答 / 办公助手** → 强调语言能力 + 对话体验
- **RAG系统（知识库问答）** → 强调真实性（Faithfulness）
- **代码生成 / 自动化** → 强调逻辑与编程能力
- **医疗 / 政务 / 金融** → 强调安全性 + 拒答能力
- **Agent系统** → 强调推理 + 工具调用能力

二、用 Benchmark 做初筛

关键指标对应关系

- 通用能力 → MMLU
- 推理能力 → GSM8K
- 对话能力 → MT-Bench
- 代码能力 → HumanEval
- 真实性 → TruthfulQA

👉 用 Benchmark 排除明显不合适的模型

三、重点看“真实效果”

必须做三类测试：

1. 业务数据测试（最关键）

- 用真实数据（如客服、政策、医疗文本）
- 看是否“答得对 + 用得上”

2. RAG一致性测试

- 回答是否基于检索内容
- 是否出现“编造信息”

3. 拒答测试（安全）

- 不该回答的问题是否拒答
- 是否胡乱给建议

四、工程与部署约束

- **成本**：API费用 / GPU成本
- **延迟**：是否满足实时性
- **部署方式**：本地 / 私有化 / 云API
- **可控性**：是否支持微调（LoRA / QLoRA）
- **生态**：是否支持 vLLM / Transformers / 工具链

👉 结论：小规模实测 > 所有Benchmark

4.开源社区简介

公司概况

- 成立于 **2016 年**，总部在纽约和巴黎
- 以 “**AI 的 GitHub**” 著称，致力于构建 **开源 AI 社区与平台**

核心产品与平台

- **Transformers**: 最广泛使用的 NLP 库（支持 BERT、GPT、LLaMA 等模型）
- **Datasets**: 大规模数据集开放平台
- **Model Hub**: 超过 60 万个开源模型共享与下载
- **Spaces**: 低代码部署与演示机器学习应用的平台

技术与生态

- 支持 **NLP、CV、语音、多模态** 等领域
- 集成主流框架：PyTorch、TensorFlow、JAX
- 提供推理 API、加速工具（Accelerate）、模型量化与优化方案

价值与影响

- 建立 **全球最大 AI 开发者社区**
- 推动 **AI 开放、共享与可复现**
- 在学术、工业界广泛应用（Meta、Google、微软、NVIDIA 等均有合作）

基本概况

- 最主流的预训练模型库，2018 年发布
- 支持 **NLP、CV、语音、多模态**
- 兼容 **PyTorch / TensorFlow / JAX**
- Model Hub 上可直接调用 **10万+ 模型**

核心功能

- **模型加载与推理**：一行代码快速使用
- **统一接口**：AutoModel / AutoTokenizer
- **多任务 pipeline**：分类、问答、翻译、摘要、生成、ASR、CV
- **训练与微调**：Trainer API，支持 LoRA/QLoRA 等高效微调
- **生态联动**：Datasets、Tokenizers、Accelerate、Optimum、PEFT

价值与应用

- **研究**：快速复现论文模型
- **工业**：企业级部署与推理优化
- **教育**：AI 教学与实验标准工具
- **产品**：聊天机器人、文档分析、语音助手、图像理解

- **AI 大模型开发的“标准工具箱”**

- **降低了研究到应用的门槛。**
<https://huggingface.co/>

基本概况

- 由 阿里巴巴达摩院 于 2022 年 11 月推出
- 中文名 “魔搭”，寓意 “模型搭建”
- 开放的 模型即服务 (Model-as-a-Service, MaaS) 社区
- 类似 Hugging Face 的 中国版开源 AI 社区

核心功能

- **模型库**: 超 5000+ AI 模型, 涵盖 NLP、CV、语音、跨模态等
- **数据集库**: 开放多领域数据, 支持在线加载与处理
- **示例库**: 提供丰富的训练/推理脚本, 快速上手
- **一键体验**: 在线 Demo 体验模型效果, 无需本地环境
- **AutoDL**: 支持自动化训练、推理和部署

技术生态

- **ModelScope SDK**: 统一调用模型的 Python 接口
- **硬件适配**: 支持本地 GPU、云端算力平台
- **工具链**: 与阿里云深度整合, 支持 训练、微调、推理、评测、部署 全流程

应用与价值

- **科研**: 国内学者快速复现与验证前沿模型
- **产业**: 企业可低成本接入中文大模型生态
- **教育**: 高校课程与竞赛使用, 降低学习门槛
- **生态**: 打造国产 AI 开源社区, 支持多语种、产业级场景

魔搭社区 = 中国版 Hugging Face <https://modelscope.cn/>

5.模型加载和推理

加载方法1：使用Transformers库



智泊AI
ZHIPO AI



魔泊云
MoPaaS

- 由 Hugging Face 开发，最常用的 NLP & LLM 框架
- 提供 模型加载、推理、微调、训练 全套工具
- 支持各种大模型（LLaMA, Qwen, ChatGLM, DeepSeek 等）
- 优点
 - 简单易用，接口统一
 - 社区活跃，文档和教程丰富
 - 适合科研和原型开发
- 缺点
 - 推理速度较慢（单机 GPU 时）
 - 大规模服务化不够高效
- 适用场景：本地科研实验、小规模推理、微调

模型加载与推理

模型加载 → Tokenize → Generate → Decode 全流程



智泊AI
ZHIPU AI



魔泊云
MoPaaS

1

加载模型

AutoModelForCausalLM
AutoTokenizer

```
from_pretrained()
```

2

Tokenize

文本 → token IDs
apply_chat_template

```
tokenizer.encode()
```

3

Generate

自回归生成
采样策略控制

```
model.generate()
```

4

Decode

token IDs → 文本
输出结果

```
tokenizer.decode()
```

推理采样参数速查

参数	含义	取值范围	常用取值
temperature	随机性控制	0.0 ~ 2.0	0.7 (通用) 0.1 (确定性)
top_p	核采样	0.0 ~ 1.0	0.9 (推荐)
top_k	截断采样	1 ~ vocab	50 (常用)
max_tokens	最大生成长度	1 ~ 上下文	512 / 2048
rep_penalty	重复惩罚	1.0 ~ 2.0	1.1 ~ 1.3

提示: temperature 与 top_p 通常二选一调整, 不建议同时修改

加载方法 2：使用 vLLM 框架快速部署



智泊AI
ZHIPU AI



魔泊云
MoPaaS

- 由UC Berkeley + CMU 团队 开发的高性能推理框架
- 专注于 大语言模型推理加速
- 核心技术：PagedAttention（高效显存管理）
- 优点
 - 推理吞吐量极高（可达 Transformers 3-10 倍）
 - 原生支持 API 部署 (api_server)
 - 支持 连续批处理 (continuous batching) → 适合多用户并发
- 缺点
 - 训练/微调支持有限（偏推理）
 - 配置比 Transformers 略复杂
- 适用场景：在线推理服务、高并发 API 部署

加载方法 2：使用 vLLM 框架快速部署



智泊AI
ZHIPU AI



魔泊云
MoPaaS

Step 1: 安装 vLLM

```
pip install vllm
```

Step 2: 启动 API Server

```
vllm serve ../models/Qwen1.5-1.8B-Chat \  
--trust-remote-code \  
--port 8000
```

加载方法 2：使用 vLLM 框架快速部署



智泊AI
ZHIPU AI



魔泊云
MoPaaS

Step 3: 发送请求

```
from openai import OpenAI

client = OpenAI(
    base_url="http://localhost:8000/v1",
    api_key="none"
)
resp = client.chat.completions.create(
    model="Qwen1.5-1.8B-Chat",
    messages=[
        {"role": "user", "content": "你好"}
    ]
)
print(resp.choices[0].message.content)
```


- 开发方：Hugging Face
- 定位：快速搭建 机器学习 Web 交互界面
- 特点：
 - 。零前端开发，几行 Python 代码即可启动网页
 - 。支持文本、语音、图像等多模态输入输出
 - 。可与 Transformers/vLLM 集成，做成 Chatbot 或 Demo
- 适用场景：研究展示、内部测试、原型系统

6.综合练习项目

电商智能客服系统

PDF知识库

上传产品文档
RAG智能检索

多轮对话

上下文记忆
连贯交互

订单查询

Function Calling
业务系统集成

用户管理

会话隔离
权限控制

五层架构总览

前端界面

Gradio

后端API

FastAPI + SSE

业务逻辑

RAG + Tools

模型层

vLLM推理

基础设施

Docker + Redis

技术路线图与四阶段里程碑



智泊AI
ZHIPO AI



魔泊云
MoPaaS



实操1：大模型加载和推理

1. 使用transformers库加载和推理
2. 实现多轮对话
3. 使用Gradio搭建可交互的网页chatbot
4. 使用vLLM框架快速部署