

L4

模型微调与 私有化大模型

训练数据处理方法（补充）

1.数据去重与相似度过滤

精确去重

数据预处理核心步骤：文本 → 哈希指纹 → 去重

什么是精确去重？

删除内容完全一样的文本样本

为什么重要？

- 避免模型记住重复样本
- 防止训练数据分布偏移
- 减少存储和计算成本
- 防止评测集泄漏到训练集

核心流程



示例

文本 A:

人工智能是计算机科学的一个分支。

文本 B:

人工智能是计算机科学的一个分支。

MD5: f1a8c3... (相同) → B 被删除

常用哈希算法

算法	特点	用途
MD5	快、128-bit	常见数据去重
SHA-1	更安全、160-bit	低碰撞率
SHA-256	更长更安全	大规模数据

Python 实现 (小规模)

```
import hashlib
seen = set()
clean_data = []

for text in texts:
    h = hashlib.md5(
        text.encode()).hexdigest()
    if h not in seen:
        seen.add(h)
        clean_data.append(text)
```

优点：快速、简单、大规模适用

缺点：无法发现轻微改写的重复

大规模：Spark distinct() / Hadoop MapReduce

下一步：Near Dedup / 语义去重

近似去重

删除内容高度相似但不完全相同的文本

什么是近似去重？

目标：删除高度相似但不完全相同的文本

示例：

文本 A: 人工智能是计算机科学的重要分支。
文本 B: 人工智能是计算机科学的一个重要分支！

→ 不完全一样，但语义几乎相同 → 应去重

为什么 Exact 去重不够？

Exact 去重只能发现：

- ✓ 完全相同
- ✗ 改一个字就检测不到

现实数据中常见：

- 论坛复制粘贴 + 改标题
- 广告模板文
- 新闻改写稿
- SEO 文章

Exact Dedup vs Near Dedup

项目	Exact Dedup	Near Dedup
检测对象	完全一样	高度相似
技术	MD5/SHA	SimHash/LSH/Jaccard
复杂度	低	较高
必要性	基础	更关键（防止模板语言）

不做 Near Dedup，模型会学到模板语言和垃圾模式

近似去重：三种主流方法

SimHash / LSH / Jaccard 相似度

SimHash：语义指纹

思想：
把文本变成二进制指纹（如64-bit）
相似文本 → 指纹只有少量bit不同
判断方法：Hamming Distance

示例：
文本A指纹：101011001...
文本B指纹：101011101...
只差 2 位 → 认为相似

特点：
✓ 速度快
✓ 适合海量数据
✓ 常用于网页去重

LSH：局部敏感哈希

思想：
相似数据更容易被分到同一个桶

流程：
1. 提取文本特征（n-gram、词向量等）
2. 用 LSH 映射到多个哈希桶
3. 只在同桶内比较相似度

优势：
避免全量两两比较（ N^2 ）

特点：
✓ 可扩展到大数据
✓ 适合搜索引擎

Jaccard 相似度

基于集合重叠：
 $J = |A \cap B| / |A \cup B|$

示例：
A = {人工智能, 计算机科学, 分支}
B = {人工智能, 计算机科学, 重要, 分支}

交集 = 3, 并集 = 4
 $J = 3/4 = 0.75 \rightarrow$ 相似度高

✓ 简单直观
✓ 常和 MinHash + LSH 结合

方法对比

方法	核心思想	优点	适用场景
SimHash	文本指纹	快速、轻量	网页/论坛去重
LSH	相似进同桶	可扩展到大数据	搜索引擎
Jaccard	集合重叠率	简单直观	分词文本

语义去重

在意义空间去重，而不是文字空间

什么是 Semantic Dedup?

目标:

即使两句话用词完全不同，只要表达的含义非常接近，就只保留一条


示例:

A: AI 在医疗中用于辅助诊断。

B: 人工智能可帮助医生进行疾病诊断。

→ 字面不同，但语义几乎一样 → 应去重

核心思想：文本 → 语义向量



相似度计算：余弦相似度

公式: $\text{sim}(A,B) = \frac{A \cdot B}{(|A| \cdot |B|)}$ 取值范围: -1 到 1

相似度解释:

> 0.9 几乎相同语义

0.8-0.9 高度相似

< 0.6 语义差异大

通常阈值: 0.85 左右

实际示例

文本 A: AI 在医疗中用于辅助诊断。

文本 B: 人工智能可帮助医生进行疾病诊断。

向量相似度 = 0.92

超过阈值 0.85

→ 认为是语义重复

→ 删除一条

语义去重：实现方法

常用模型与大规模解决方案

常用句向量模型

模型	特点
Sentence-BERT	专门优化句子相似度
mBERT	多语言表示
SimCSE	对比学习训练，效果强
MiniLM	轻量级、快速

大规模数据解决方案

问题：如果有上亿句子，不能两两比较
工具：FAISS (Facebook AI)

流程：

1. 所有文本 → 向量化
2. 建立向量索引 (ANN)
3. 对每个向量查找最近邻
4. 相似度超过阈值 → 标记为重复

复杂度： $O(N^2) \rightarrow O(N \log N)$

三种去重方法对比

类型	判断依据	能发现什么
Exact Dedup	字符完全一致	复制粘贴
Near Dedup	词/结构相似	小改写
Semantic Dedup	语义向量相似	意义相同的不同表达

为什么这对大模型训练重要？

语义去重能：

- ✓ 提升信息密度
- ✓ 提高知识覆盖面
- ✓ 减少数据偏见
- ✓ 节省训练算力

不做语义去重的后果：

- X 模型学到同一句话的多种改写
- X 数据多样性下降
- X 泛化能力变差
- X 训练浪费算力

2. 有害内容过滤



智泊AI
ZHIPO AI



魔泊云
MoPaaS

敏感词词典过滤

最基础、最快速的方法 - 有害内容过滤的第一道防线

有害内容过滤的目标

避免模型学习到：

违法、暴力、色情、仇恨、极端主义

否则会导致：

- 模型输出不当言论
- 法规风险
- 企业合规问题
- 安全事故

这是训练数据清洗中的合规关卡

示例

文本：XXX 暴力组织

匹配黑名单 → 直接删除

词典过滤做法

1. 构建黑名单词典

- 色情词
- 暴力词
- 仇恨言论
- 涉恐涉极端主义

2. 用正则匹配文本

匹配黑名单 → 直接删除

优点：

速度极快、可规模化

缺点：

- 谐音梗、变形词识别不了
- 容易误杀正常文本

分类模型 & 人工审核

智能识别 + 关键样本复核

方法二：分类模型过滤

能理解上下文，比词典更智能

常用工具：

工具	能检测
Detoxify	仇恨、侮辱、攻击性
Perspective API	toxic、insult、sexual等

输出示例：

Toxic: 0.82, Insult: 0.76 设置阈值 > 0.5 → 过滤

方法三：人工抽检

适用于：医疗、教育、法律、高风险领域

原因：模型难识别复杂语境或专业风险

例子：

医生建议患者自残

模型可能只看到医生、建议

人工能判断这是危险内容

通常用于：抽样复查、误判复核、灰色样本

为什么需要模型而不仅是词典？

词典方法无法识别：某群体天生智商低

→ 没有敏感词，但属于仇恨言论

→ 分类模型能识别语义攻击

3. 数据质量检测

困惑度 Perplexity (PPL)

语言模型觉得这句话难不难预测 - 流畅度检测核心方法

流畅度检测的目标

判断文本像不像正常人类语言

要过滤掉:

- 乱码
- 语法崩坏句
- 低质量机器翻译
- 模板化生成垃圾文本

困惑度 (PPL) 公式

$$PPL = 2^{(-1/N \sum \log P(w_i))}$$

核心理想: 语言模型预测每个词的难度

不自然的句子 → **模型预测困难** → **PPL 高**

PPL 值解释

PPL 值	含义	状态
< 50	自然流畅	✓
50-150	可疑	?
> 150	很可能异常	✗

示例对比

✓ 人工智能是计算机科学的一个分支。

PPL ≈ 20

✗ 科学分支分支计算计算计算

PPL ≈ 200

句法检查 & LLM 评估

结构对不对 + 像不像人写的

方法二：句法检查

用 NLP 工具分析句子结构

工具：spaCy、Stanza

检查点：

检测项	说明
主谓结构	是否有完整句子
词性序列异常	连续名词、动词堆叠
重复模式	计算计算计算

例子：

✓ AI 可以帮助医生。

✗ 帮助医生 AI。（结构异常）

方法三：LLM 自动评估

用大模型做语言评审

Prompt 示例：

判断以下文本是否自然流畅、符合人类表达习惯。

模型：GPT-4、Qwen 等

适合：

- 小规模高精度清洗
- 最终兜底筛选

三种方法对比

方法	优点	缺点	适用阶段
PPL	快、自动化	不理解语义	大规模初筛
句法检查	可解释	对复杂语言弱	中间筛选
LLM 评估	最接近人类	贵、慢	最终精筛

术语一致性检测

Terminology Consistency - 确保专业表达统一



智泊AI
ZHIPO AI



魔泊云
MoPaaS

专业性检测的目标

确保训练数据：

- ✓ 用语专业
- ✓ 知识正确
- ✓ 数据结构规范

否则模型可能学到：

- 错误医学知识
- 过期法律条款
- 术语混乱

术语一致性问题

问题：

同一个概念用不同表达，
模型会混淆

后果：

- 模型难学到标准知识结构
- 信息抽取结果不稳定

解决方法

1. 建立领域术语词典
标准术语 ↔ 口语化表达映射
2. 规则替换或标注规范化
自动将口语化表达转为标准术语

示例：医学术语

表达	问题
高血压	标准术语 ✓
血压高	口语化 ✗

知识正确性检测

Factual Correctness - 最关键的一步



检测方法

将文本与权威知识源比对

权威来源:

- 医学指南
- 法律法规
- 金融监管条款
- 科学文献

技术手段:

- 知识库匹配
- 规则验证
- 事实核查模型

示例：医学知识

✓ **正确:** 正常体温 36-37.5°C

✗ **错误:** 正常体温 38°C

如果不删除错误数据:

- 模型可能学到错误医学常识
- **高风险!**

不同领域的风险

医疗: 错误诊断建议 → 危及生命

法律: 过期法条 → 误导决策

金融: 错误监管信息 → 合规风险

教育: 错误知识点 → 误导学习

标注一致性 & 三类对比

Annotation Consistency - 数据结构规范

标注一致性检测

在对话或结构化数据中尤为重要

✓ 正确格式

```
{  
  "role": "user",  
  "content": "我头疼怎么办?"  
}
```

问题:

- 字段混乱 (role vs speaker)
- 角色错置 (user vs assistant)
- 结构不统一 (content vs text)

→ 会直接影响模型训练稳定性

✗ 错误数据

```
{  
  "speaker": "assistant",  
  "text": "我头疼怎么办?"  
}
```

三类检测对比

类型	解决问题	风险
术语一致性	表达是否标准	模型理解混乱
知识正确性	内容是否真实	模型学到伪知识
标注一致性	数据结构是否统一	训练异常

三位一体：术语标准 + 知识正确 + 结构规范 = 高质量专业数据

语义质量筛选

Semantic Quality Selection - 提高单位token的知识密度

什么是语义质量筛选？

目标：过滤掉语言没问题、也不违规，但信息价值很低的文本

要删除的内容：

- SEO 垃圾文章
- 模板化广告文
- 空洞套话
- 无信息量段落

为什么这一步很重要？

大模型训练受限于token数量

如果 30% 数据是废话：

- 模型浪费算力学习无效模式
- 知识覆盖下降
- 泛化能力变差

目标：提高单位token的知识密度

典型低质量语义样本

类型	示例	问题
套话文	随着社会不断发展，我们要与时俱进...	无知识
SEO文	关键词堆砌文章	重复冗余
广告模板	点击这里了解更多优惠！	无学习价值
内容重复	同一句换说法	信息量低

与其他步骤的区别：

流畅度（是否像正常语言）→ 安全过滤（是否违规）→ 专业知识（是否正确）→ 语义质量（是否有价值）

让模型多学知识、少学废话 - 显著影响模型上限能力

三种筛选方法

从智能评估到统计特征再到领域特异性

方法一：LLM质量打分

使用大模型评估

Prompt 示例：

请判断以下文本的信息量是否高，是否包含实质性知识。

输出分数：

1 = 废话

5 = 高知识密度

低于阈值 → 删除

方法二：统计特征检测

无需大模型，成本低

指标	作用
重复n-gram比例	判断是否模板化
句子多样性	防止关键词堆砌
词汇丰富度	信息密度估计
长度vs信息比	过滤长废话

方法三：领域关键词密度

在专业模型中：

- 医疗文本中是否含有医学术语
- 法律文本是否出现法条结构
- 没有领域特征 → 信息价值低

三种方法对比

LLM 打分

✓ 最准确
X 成本高、慢

统计特征

✓ 快速、可规模化
X 准确度中等

领域关键词

✓ 专业性强
X 需要领域知识

组合使用：统计特征初筛 → LLM精筛 → 领域关键词验证（专业模型）

数据集质量评估（一）

Dataset Evaluation - 从整体统计视角判断数据是否达标

① 多样性 Diversity

如果数据太单一，模型就会思维单一

维度	指标
词汇多样性	Type/Token Ratio
句型多样性	句法结构分布
文体多样性	叙述 / 说明 / 对话
主题多样性	Topic clustering

问题示例：70% 数据都是"产品介绍"风格 → **模型语言模式单一**

② PPL 分布（语言自然度分布）

对全数据计算 PPL，画分布曲线

理想情况：

- 中低区间集中
- 少量高 PPL（复杂文本）

异常情况：

- 高 PPL 尾部过长 → 乱码残留
- PPL 极低集中 → 数据过于模板化

用于判断语言质量是否均衡

③ 主题覆盖度 Topic Coverage

通过主题建模（LDA / Embedding 聚类）

检查是否：

- 覆盖科技、教育、生活等领域
- 是否某领域过多

否则模型会：

在某领域很强，**在其他领域很弱**

多样性 + PPL分布 + 主题覆盖 = 数据丰富度评估

数据集质量评估 (二)

LLM 质量打分 & 长度分布

④ LLM 质量打分

LLM-based Quality Assessment

方法：抽样数据，让大模型评价

评估维度：

- 信息量
- 表达质量
- 逻辑清晰度
- 专业度

输出整体均值，判断数据集“认知质量”

⑤ 长度分布 (常被忽略)

检查：

- 平均 token 数
- 长文本比例

问题：

- 全是短句 → 推理能力差
- 全是长文 → 对话能力弱

理想分布：

短 / 中 / 长文本均衡
适应各种场景需求

完整评估框架

多样性

PPL分布

主题覆盖

LLM质量

长度分布

五维评估 = 全面数据集健康度 - 确保高质量训练数据