

L4

模型微调与 私有化大模型

2. 微调数据处理方法

一、微调数据 vs 预训练数据：核心差异

核心差异对比

维度	预训练数据	微调数据
规模	数万亿 tokens	数千到数十万条
质量要求	中等，靠量取胜	极高，每条数据都影响模型行为
数据形态	无标注的纯文本	结构化的指令-回答对 / 偏好对
目标	学习语言知识和世界知识	激发/对齐特定能力与行为模式
核心挑战	规模与效率	质量、多样性与平衡性

核心原则：质量 >> 数量。LIMA 论文证明仅 1000 条精选数据即可显著提升模型表现，而低质量数据反而会让模型退化。

二、微调数据的采集与构建

2.1 数据格式类型 — SFT 数据

单轮指令-回答对格式:

```
{  
  "instruction": "请解释量子纠缠的概念",  
  "input": "",  
  "output": "量子纠缠是指两个或多个粒子之间..."  
}
```

多轮对话格式:

```
{  
  "conversations": [  
    {"role": "system",    "content": "你是一位专业的物理学教授"},  
    {"role": "user",      "content": "请解释量子纠缠"},  
    {"role": "assistant", "content": "量子纠缠是指..."},  
    {"role": "user",      "content": "能举一个日常生活中的类比吗? "},  
    {"role": "assistant", "content": "可以想象一对手套..."}  
  ]  
}
```

2.1 数据格式类型 — 偏好数据 & 工具调用

偏好数据格式（用于 DPO/RLHF）：

```
{  
  "prompt": "解释什么是机器学习",  
  "chosen": "机器学习是人工智能的一个分支，它让计算机能够...",  
  "rejected": "机器学习就是让电脑自己学习东西。简单来说..."  
}
```

带工具调用的数据格式：

```
{  
  "conversations": [  
    {"role": "user", "content": "北京今天天气怎么样? "},  
    {"role": "assistant", "content": null,  
     "tool_calls": [{"name": "get_weather", "arguments": {"city": "北京"}}]},  
    {"role": "tool", "content": "{\"temp\": 22, \"weather\": \"晴\"}"},  
    {"role": "assistant", "content": "北京今天天气晴朗，气温22°C..."}  
  ]  
}
```

2.2 数据来源

- 人工标注（最高质量）：由领域专家或专业标注员根据详细指南编写。成本每条约 \$1-10。需制定详细标注规范、多标注员交叉验证、设置质检环节。适用于核心能力数据、安全对齐数据、高风险领域数据。
- 基于强模型生成（性价比最高）：用 GPT-4、Claude 等强模型生成训练数据。常用方法包括 Self-Instruct、Evol-Instruct、直接批量生成。需注意后续质量过滤（通过率通常 60%-80%）、输出同质化问题、模型使用条款限制。
- 开源数据集整合：通用型（OpenAssistant、ShareGPT、Alpaca、FLAN Collection、UltraChat）、代码类（CodeAlpaca、Magicoder-OSS-Instruct）、数学类（MetaMathQA、GSM8K-augmented）、中文类（BELLE、Firefly、MOSS-SFT、InfinityInstruct）。整合时需统一格式、去重、质量筛选、检查许可证。
- 从真实用户交互中提取：收集模型上线后的真实用户对话（需用户同意），筛选高质量交互并脱敏。最贴近真实使用场景。ShareGPT 数据集是这一思路的代表。
- 从已有文档/知识库转化：针对企业场景，将内部文档、FAQ、知识库用大模型转化为多样化的问答对。适合构建领域特定的微调数据。

2.3 数据规模参考

微调目标	典型数据量	说明
轻量对齐（通用助手）	1K-10K 条	质量极高即可见效
特定任务微调	5K-50K 条	如摘要、翻译、分类
领域适配	10K-100K 条	如医学、法律、金融问答
全面能力微调	100K-1M 条	多任务混合，如 LLaMA-2-Chat
偏好对齐（DPO/RLHF）	10K-200K 对	需要 chosen/rejected 对

三、微调数据的清洗与质量控制

3.1 格式校验 — 必检项目

微调数据有严格的格式要求，格式错误会直接导致训练失败或效果异常。

- JSON 格式完整性：所有字段是否存在、类型是否正确
- 角色交替合法性：user/assistant 是否严格交替出现
- 空值检测：instruction 或 output 是否为空或仅含空白字符
- 特殊 token 冲突：数据内容中是否意外包含模型的特殊 token
- 编码问题：是否存在乱码、非法 Unicode 字符
- 长度合规：是否超出模型的上下文窗口长度

3.1 格式校验 — 常见格式问题

问题	影响	解决方案
output 以「当然可以！」等套话开头	模型学会无意义的开场白	正则匹配 + 裁剪
多轮对话中 assistant 连续出现	训练 loss 异常	校验角色交替
包含 markdown 乱码或截断	模型输出格式混乱	渲染检查 + 修复
system prompt 不一致	模型行为不稳定	统一或按策略分组

3.2 内容质量过滤 — 回答质量评估

微调数据的质量过滤比预训练更注重语义层面。

- 正确性：回答是否包含事实错误。有标准答案的任务可程序化验证；开放问题可用强模型做 Judge 打分。
- 完整性：是否充分回答了指令中的所有要求，检测指令中的多个子问题是否都被覆盖。
- 相关性：回答是否紧扣指令，没有离题。
- 有害性：是否包含有害、偏见或不当内容。
- 格式规范：回答的格式是否符合预期（如要求 JSON 输出时是否真的是合法 JSON）。

3.2 内容质量过滤 — LLM-as-Judge

基于大模型的质量评估（LLM-as-Judge）是微调数据质量控制中最常用的方法。

评估维度：

1. 指令遵循度（1-5）：回答是否严格按照指令要求执行
2. 准确性（1-5）：信息是否正确无误
3. 详细程度（1-5）：回答的深度和细节是否恰当
4. 表达质量（1-5）：语言是否流畅、逻辑是否清晰
5. 安全性（通过/不通过）：是否包含不当内容

综合评分 < 3 的数据建议移除

⚠ 注意：使用多个评估维度；考虑多个 Judge 模型交叉验证；LLM Judge 对长度有偏好；建议对 5%-10% 的数据进行人工抽检。

3.3 去重

- **指令去重（最重要）**：完全相同的指令用精确字符串匹配去除。语义相似的指令用 embedding 模型（如 BGE、E5）计算相似度，余弦相似度 $> 0.85-0.90$ 的视为近似重复，保留回答质量更高的那条。
- **回答去重**：不同指令但回答高度相似，说明模型/标注员在套用模板。通过计算回答的 n-gram 重叠率或 embedding 相似度检测。少量合理重复可保留，大量重复需要清理。
- **来源级去重**：混合多个开源数据集时，不同数据集之间可能存在大量重叠（如 ShareGPT 数据可能已被多个下游数据集包含）。需要跨数据集进行去重。

3.4 安全与合规过滤

- **有害内容检测与处理：**使用毒性分类器检测有害指令和回答。区分两种情况：恶意指令+配合性回答→必须移除或改为安全拒绝；正常指令+意外有害回答→修正回答或移除。同时检查是否有 prompt injection 类数据混入。
- **PII（个人身份信息）清理：**比预训练数据更严格，因为微调数据中的 PII 更容易被模型记忆化。检测并替换真实姓名、邮箱、电话、地址、身份证号。对于来自真实用户对话的数据，PII 清理是必须步骤。
- **版权与许可：**检查回答中是否包含受版权保护的大段内容（如书籍段落、歌词）。使用开源数据集时确认其许可证允许你的使用场景。部分数据集禁止商业使用（如基于 GPT-4 输出的数据集可能受 OpenAI 条款限制）。

四、数据多样性与平衡

4.1-4.2 多样性的重要性 & 任务类型覆盖

微调数据的多样性直接决定了模型的泛化能力。数据过于集中在某类任务会导致灾难性遗忘。

任务类别	示例	建议占比（通用助手）
知识问答	事实查询、概念解释	15-20%
推理分析	逻辑推理、数学计算、因果分析	15-20%
创意写作	故事、诗歌、文案、邮件	10-15%
代码相关	编写、调试、解释代码	10-15%
文本处理	摘要、翻译、改写、纠错	10-15%
多轮对话	追问、澄清、上下文引用	10-15%
指令遵循	格式要求、约束条件、角色扮演	5-10%
安全拒绝	拒绝有害请求、边界情况处理	5-10%

4.3 难度分布

数据难度应呈合理分布，不宜全部是简单问题或全部是高难度问题：

简单 (30%)

直接的事实查询、简单指令

中等 (50%)

需要一定推理或专业知识

困难 (20%)

复杂推理、多步骤任务、专业领域深度问题

难度评估方法：

- 指令长度和复杂度 / 所需推理步骤数
- 领域专业程度 / 约束条件数量
- 用弱模型测试，正确率低的即为「难」

4.4 长度分布

回答长度应有合理的变异：

- 简短回答（1-3 句）：20-30%
- 中等回答：40-50%
- 详细回答：20-30%

避免所有回答都长篇大论（模型会学到啰嗦），也避免都过于简短。指令中明确要求「简短」或「详细」时，回答长度应与要求匹配。

4.5-4.6 语言风格多样性 & 检测补充

语言与风格多样性

- 多语言模型需控制不同语言的比例
- 同一语言内风格应多样化：正式/口语、技术性/通俗化
- 避免所有回答使用相同句式模式（如每次都以「当然！」开头）

多样性检测方法

- 对所有指令做 embedding 聚类查看分布是否均匀
- 统计关键词/主题的频率分布
- 计算回答的 n-gram 多样性指标 (Distinct-n)

不足时的补充策略：

- 定向生成：识别覆盖不足的类别，用大模型定向生成
- 改写扩展：对现有数据进行改写，增加表述多样性
- 从外部数据集补充特定类别

五、特定微调场景的数据处理

5.1 领域适配微调

目标：让通用模型掌握特定领域的知识和表达方式。

数据构建流程：

1. 收集领域文档（论文、教材、手册、案例）
2. 用大模型从文档中提取知识点，生成多样化的问答对
3. 由领域专家审核和修正
4. 补充领域特有的推理/判断类问题

关键注意事项：

- 领域术语的一致性：同一概念在不同数据中的称呼需要统一
- 专业知识的准确性：必须由领域专家把关，大模型生成的专业内容可能有隐蔽错误
- 保持通用能力：纯领域数据微调容易导致通用能力下降，需混入一定比例的通用数据（通常 20-40%）

5.2 偏好对齐微调 (DPO/RLHF)

偏好对数据的构建方法:

- 方法一：多模型/多采样生成 — 同一 prompt 下让不同模型或同一模型（不同温度/采样参数）生成多个回答，由人工或 LLM Judge 选出 chosen 和 rejected。
- 方法二：故意降质 — 对已有 SFT 数据，故意生成降质版本作为 rejected：引入事实错误、删减关键信息、添加冗余废话、忽略部分指令要求、降低格式规范性。
- 方法三：线上隐式反馈 — 从线上数据中收集用户的隐式反馈（点赞/踩、重新生成、编辑修改）。

质量要点：chosen 和 rejected 之间要有明确的质量差异；差异应体现在实质内容上而非仅长度；覆盖多种偏好维度（准确性、有用性、安全性、格式规范）；同时需要简单区分和困难区分的样本。

5.3 工具调用 / Agent 微调

数据要素：

- 工具定义 (function schema)
- 用户请求
- 模型判断：是否需要调用工具、调用哪个工具、参数是什么
- 工具返回结果
- 模型基于结果的最终回答

数据构建关键：

- 包含「不需要调用工具」的负样本（避免模型过度调用工具）
- 包含多轮工具调用（一次请求需要连续调用多个工具）
- 包含工具调用失败/报错后的处理
- 参数填充的准确性需要严格验证

5.4 多轮对话微调

数据特点

- 对话轮次通常 3-10 轮
- 需包含指代消解（「它」「那个」指代上文）
- 需包含话题转换和追问
- 需包含用户纠正模型错误的场景

常见问题

- 多轮数据中，后续轮次的回答质量经常不如第一轮
- 需要确保每一轮回答都经过质量控制
- 对话的连贯性和一致性需要整体审核

5.5 长文本微调

- 确保数据确实利用了长上下文（而非短问题 + 长但无用的回答）
- 需要包含对上下文中远距离信息的引用和推理
- 常见构造方式：基于长文档的问答、长文档摘要、多文档综合分析
- 注意长文本 tokenize 后不超过模型的上下文窗口限制

六、数据增强与合成（微调专用策略）

6.1 指令改写与进化

Evol-Instruct (WizardLM 方法)：从简单指令出发，通过以下策略逐步进化：

- 增加约束：「写一首诗」→「写一首关于秋天的七言绝句，不能使用「落叶」这个词」
- 增加推理步骤：「计算面积」→「一个不规则多边形，给出顶点坐标，要求先分割为三角形再求面积」
- 换角度提问：将「解释X」改为「从反对者的角度评价X」
- 增加背景信息：给指令添加具体的场景和上下文

指令回译：给定一个高质量回答，用大模型反推可能的指令。适合从已有知识库中挖掘微调数据。

6.2 回答增强

- **拒绝采样 (Rejection Sampling)**：对同一指令让模型生成 K 个（如 10-20 个）回答，用验证器（正确性检查）或 Reward Model 打分，只保留得分最高的 1-2 个作为训练数据。在数学和代码任务中效果尤为显著。
- **思维链补充**：对推理类问题确保回答包含详细推理过程。可以让大模型对已有的简短回答补充推理链。格式举例：「让我们一步步分析... 第一步... 第二步... 因此...」
- **自我修正数据**：构造「初始回答（有缺陷）→ 反思 → 修正后的回答」的训练数据，帮助模型学会自我检查和修正。

6.3 针对弱点的定向数据生成

迭代流程：

- ① 在评估集上测试当前模型，找到薄弱环节
- ② 分析错误模式：是知识不足、推理错误还是指令理解偏差
- ③ 针对性地生成该类型的训练数据
- ④ 混入整体训练集重新微调
- ⑤ 再次评估，迭代进行

七、数据预处理与训练准备

7.1 对话模板 (Chat Template)

不同模型使用不同的对话模板，对模型行为有重要影响。

ChatML 格式:

```
<|im_start|>system  
你是一个有用的助手。<|im_end|>  
<|im_start|>user  
请解释量子力学。<|im_end|>  
<|im_start|>assistant  
量子力学是...<|im_end|>
```

LLaMA 格式:

```
[INST] <<SYS>>  
你是一个有用的助手。  
<</SYS>>  
请解释量子力学。 [/INST] 量子力学是...
```

关键处理：所有数据必须统一转换为目标模型的对话模板格式；训练时只对 assistant 回答部分计算 loss（其余 mask 掉）；确保特殊 token 的正确添加和位置。

7.2 长度处理

截断策略：

- 超过最大长度的数据：截断或丢弃
- 截断位置的选择：优先保留完整的回答，可以截断过长的上下文
- 对于多轮对话，可以将过长的对话拆分为多个训练样本（滑动窗口）

打包 (Packing)：

- 将多个短样本拼接到一个训练序列中，提高 GPU 利用率
- 需要使用 attention mask 确保不同样本之间不产生注意力交互
- 可以显著减少 padding 浪费（尤其是数据长度差异大时）

7.3 数据洗牌与分组

- 训练前充分打乱数据顺序
- 如果不同类型的数据量差异大，可以在 batch 内做分层采样
- 确保每个 batch 中的数据多样性
- 设置验证集（通常 5%-10%），用于监控训练过程

八、质量验证与迭代

8.1 训练前验证 — 自动化检查清单

- ✓ 格式完整性校验通过
- ✓ 无空回答或纯空白回答
- ✓ 去重完成（指令级、回答级、跨数据集）
- ✓ PII 清理完成
- ✓ 有害内容过滤完成
- ✓ 长度分布合理
- ✓ 任务类型覆盖全面
- ✓ 对话模板转换正确
- ✓ token 化后长度未超限
- ✓ 人工抽检样本质量合格

统计报告应包含：数据总量及各类型分布、长度分布统计、语言分布、来源分布、质量评分分布。

8.2 训练中监控 & 8.3 训练后评估与数据迭代

训练中监控：

- 监控 training loss 曲线：异常跳变可能说明数据有问题
- 监控 validation loss：过早上升说明过拟合
- 定期采样查看模型输出：直觉判断模型是否在正确方向上学习

评估方法：

- 标准 Benchmark：MMLU、HumanEval、GSM8K、MT-Bench
- 领域特定评估集 / 人工盲评（最可靠但最费时） / LLM-as-Judge 自动评估

迭代策略：

识别短板 → 针对性补充数据 → 重新微调 → 再次评估。通常需要 3-5 轮才能达到满意效果。每轮记录数据版本和对应的评估结果。

九、常用工具与框架

9.1 数据处理工具

工具	用途
HuggingFace Datasets	加载、处理、格式转换微调数据集
Argilla	数据标注、质量审核与协作平台
Label Studio	开源数据标注工具
LiteLLM / vLLM	批量调用大模型生成/评估数据
text-dedup	大规模去重
Sentence-Transformers	计算文本 embedding 用于语义去重和聚类
Presidio	PII 检测与脱敏

9.2 微调框架

框架	特点
LLaMA-Factory	多模型支持、多种微调方法、Web UI
Axolotl	配置驱动、灵活的数据混合
Swift (ModelScope)	阿里开源、中文生态友好
TRL (HuggingFace)	官方库、支持 SFT/DPO/PPO
Unsloth	极致效率优化、内存节省
OpenRLHF	专注 RLHF/DPO 训练

9.3 数据质量评估工具

工具/方法	用途
AlpacaEval	自动评估指令跟随质量
MT-Bench	多轮对话能力评估
Arena-Hard	难度较高的自动评估
Deita	数据质量和复杂度自动评分
InsTag	指令标签分类与多样性分析

十、常见陷阱与最佳实践

10.1 常见陷阱

- 数据量幻觉：盲目追求数据量，忽视质量，导致模型学到大量噪声
- 同质化问题：大量合成数据风格雷同，模型输出千篇一律
- 灾难性遗忘：纯领域数据微调导致通用能力严重退化
- 长度偏好：训练数据中长回答与高质量绑定，模型学会了无意义地啰嗦
- 数据泄露：评估集的数据出现在训练集中，导致评估结果虚高
- 标注偏差：标注员的个人偏好被模型学习，导致输出风格偏向特定群体
- 过度安全：安全拒绝数据过多，模型变得过度敏感，正常请求也被拒绝

10.2 最佳实践

- 从小开始：先用 1K-5K 条高质量数据训练基线，再逐步扩展
- 质量把关前置：每批新数据都经过完整的质量流水线后再加入训练集
- 保持多样性：定期分析数据分布，确保任务类型、难度、长度、风格的均衡
- 评估驱动：以下游评估指标指导数据选择和配比调整
- 版本管理：每次数据变更都记录版本，便于回溯和对比实验
- 混入通用数据：即使做领域微调，也保留 20-40% 的通用数据防止遗忘
- 人工在回路：自动化流程 + 定期人工抽检，两者缺一不可
- 迭代优化：数据处理不是一次性工作，需要持续迭代

实践：微调数据处理方法

- 实践1：从自由文本生成微调数据
 - 实践2：微调数据格式转换
 - 实践3：数据处理与清洗流水线演示
 - 实践4：语料去重与相似度过滤
 - 实践5：数据质量与安全清洗
-
- 详细内容参考练习手册